TA3 Actividades de optimización y cálculo matricial

3 Gradiente

☐ **(PER 25-6-2024)** Sea $\mathcal{L}:\mathbb{R}^D\to\mathbb{R}$ una función objetivo doblemente diferenciable, con gradiente $\boldsymbol{g}(\boldsymbol{\theta})=\nabla\mathcal{L}(\boldsymbol{\theta})$ y Hessiana $\boldsymbol{H}(\boldsymbol{\theta})=\nabla^2\mathcal{L}(\boldsymbol{\theta})$. Sean $\boldsymbol{g}^*=\boldsymbol{g}(\boldsymbol{\theta})|_{\boldsymbol{\theta}^*}$ y $\boldsymbol{H}^*=\boldsymbol{H}(\boldsymbol{\theta})|_{\boldsymbol{\theta}^*}$, respectivamente, el gradiente y Hessiana de $\mathcal{L}$ en $\boldsymbol{\theta}^*\in\mathbb{R}^D$. En relación con las condiciones de optimalidad local del objetivo en $\boldsymbol{\theta}^*$, indica la respuesta incorrecta o la última opción si las tres primeras son correctas.

1. $\boldsymbol{g}^*=\boldsymbol{0}$ es condición necesaria para que $\boldsymbol{\theta}^*$ sea mínimo local Es condicion necesaria, pero no suficiente
2. $\boldsymbol{H}^*\succeq 0$ (semidefinida positiva) es condición suficiente para que $\boldsymbol{\theta}^*$ sea mínimo local Cuando la segunda derivada es positiva y la primera derivada == 0, entonces es un mínimo local
3. Si $\boldsymbol{g}^*=\boldsymbol{0}$ y $\boldsymbol{H}^*$ es indefinida, $\boldsymbol{\theta}^*$ es mínimo o máximo local F. Cuando H* es indefinida, es un punto de silla
4. Las tres opciones anteriores son correctas

Solución: La 3; puede ser un punto de silla ($D=2$).

☐ Sean la función $f(\boldsymbol{x})=a_1x_1^4+a_2x_2^4$ con $a_1,a_2<0$, $\boldsymbol{x}$ un punto estacionario de f, y $\mathbf{H}(\boldsymbol{x})$ la Hessiana de f evaluada en $\boldsymbol{x}$. Indica la respuesta correcta:

1. $\mathbf{H}(\boldsymbol{x})=\operatorname{diag}(4a_1x_1^3,4a_2x_2^3)$ y $\boldsymbol{x}$ es mínimo (local) de f
2. $\mathbf{H}(\boldsymbol{x})=\operatorname{diag}(4a_1x_1^3,4a_2x_2^3)$ y $\boldsymbol{x}$ es máximo (local) de f
3. $\mathbf{H}(\boldsymbol{x})=\operatorname{diag}(12a_1x_1^2,12a_2x_2^2)$ y $\boldsymbol{x}$ es mínimo (local) de f
4. $\mathbf{H}(\boldsymbol{x})=\operatorname{diag}(12a_1x_1^2,12a_2x_2^2)$ y $\boldsymbol{x}$ es máximo (local) de f

Solución: La 4.

In [ ]:
```
import numpy as np; import matplotlib.pyplot as plt
R = np.linspace(-1, 1, 50); X1, X2 = np.meshgrid(R, R); X = np.c_[np.ravel(X1), np.ravel(X2)]
a = np.array([-1, -1]); Y = (np.power(X, 4) @ a).reshape(X1.shape)
fig = plt.figure(figsize=(6, 2)); ax = plt.subplot(121)
cp = ax.contourf(X1, X2, Y, 15, cmap='Blues_r'); plt.colorbar(cp, ax=ax, shrink=.8)
r = np.linspace(-1, 1, 15); x1, x2 = np.meshgrid(r, r); x = np.c_[np.ravel(x1), np.ravel(x2)]
neg_grad = -np.power(x, 3) @ np.diag(4 * a)
ax.quiver(x[:, 0], x[:, 1], neg_grad[:, 0], neg_grad[:, 1], color='C1');
ax = plt.subplot(122, projection='3d'); ax.set_xlabel('$x_1$'); ax.set_ylabel('$x_2$')
ax.set_title(rf'$y={a[0]:.1f}\,x_1^4{a[1]:+.1f}\,x_2^4$'); ax.text(0, 0, 0, '*')
ax.plot_wireframe(x1, x2, a[0]*x1**4 + a[1]*x2**4);
```

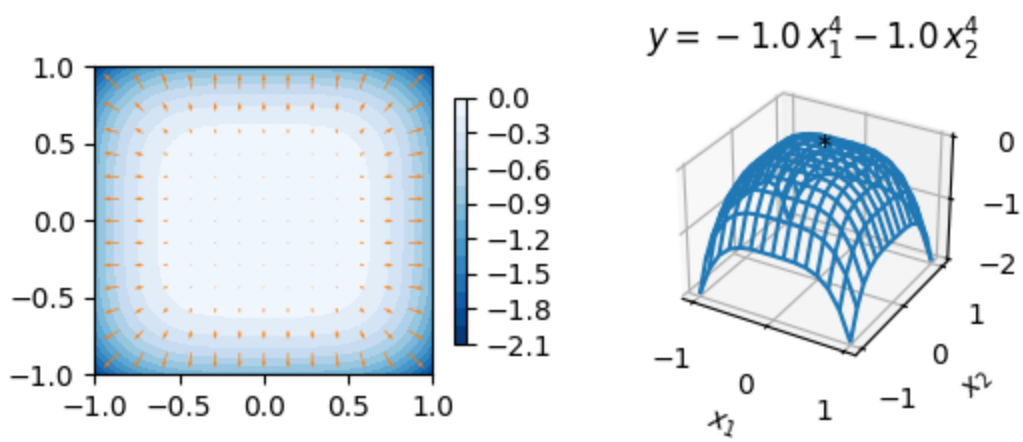

5 Descenso por gradiente

Problema: Dada la función objetivo $\mathcal{L}(\theta) = \theta^4$, aplica dos iteraciones de descenso por gradiente a partir de $\theta_0 = 1$, con factor de aprendizaje $\eta = 0.1$

Solución:

$$\frac{d\mathcal{L}(\theta)}{d\theta} = 4\,\theta^3$$
$$\theta_1 = \theta_0 - 0.1 \cdot 4 \cdot \theta_0^3 = 1 - 0.4 \cdot 1^3 = 0.6$$
$$\theta_2 = \theta_1 - 0.1 \cdot 4 \cdot \theta_1^3 = 0.6 - 0.4 \cdot (0.6)^3 = 0.5136$$

In [ ]:
```
import numpy as np
def GD1d(g, x0, eta=0.1, tol=1e-3, max_iter=2):
    x = x0; delta = np.inf; i = 0
    while np.max(np.abs(delta)) > tol and i < max_iter:
        x = x - eta * g(x); i = i + 1
        print(f'x = {x:.4f} f = {f(x):.4f}')
```

In [ ]:
```
f = lambda t: np.power(t, 4); g = lambda t: 4 * np.power(t, 3); GD1d(g, 1)
```

```
x = 0.6000 f = 0.1296
x = 0.5136 f = 0.0696
```

Problema: Dada la función objetivo $\mathcal{L}(\theta) = \theta^4$, aplica dos iteraciones de descenso por gradiente con momentum a partir de $\theta_0 = 1$, con factor de aprendizaje $\eta = 0.1$ y $\beta = 0.9$

Solución:

$$\frac{d\mathcal{L}(\theta)}{d\theta} = 4 \cdot \theta^3$$
$$m_1 = \beta\, m_0 + g(\theta_0) = 0.9 \cdot 0 + 4 \cdot \theta_0^3 = 4$$
$$\theta_1 = \theta_0 - \eta\, m_1 = 1 - 0.1 \cdot 4 = 0.6$$
$$m_2 = \beta\, m_1 + g(\theta_1) = 0.9 \cdot 4 + 4 \cdot \theta_1^3 = 4.4640$$
$$\theta_2 = \theta_1 - \eta\, m_2 = 0.6 - 0.1 \cdot 4.4640 = 0.1536$$

In [ ]:
```
import numpy as np
def GD1d_momentum(g, x0, eta=0.1, beta=0.9, tol=1e-3, max_iter=2):
    x = x0; delta = np.inf; i = 0; m = np.zeros_like(x)
    while np.max(np.abs(delta)) > tol and i < max_iter:
        m = beta * m + g(x); x = x - eta * m; i = i + 1
        print(f'm = {m:.4f} x = {x:.4f} f = {f(x):.4f}')
```

In [ ]:
```
f = lambda t: np.power(t, 4); g = lambda t: 4 * np.power(t, 3); GD1d_momentum(g, 1)
```

```
m = 4.0000 x = 0.6000 f = 0.1296
m = 4.4640 x = 0.1536 f = 0.0006
```

Problema: Dada la función objetivo $\mathcal{L}(\theta) = \theta^4$, aplica dos iteraciones de descenso por gradiente con momentum Nesterov a partir de $\theta_0 = 1$, con factor de aprendizaje $\eta = 0.1$ y $\beta = 0.9$

Solución:

$$
\begin{aligned}
\frac{d\mathcal{L}(\theta)}{d\theta} &= 4 \cdot \theta^3 \\
m_1 &= \beta\, m_0 - \eta\, g(\theta_0 + \beta\, m_0) = 0 - 0.1 \cdot 4 \cdot 1^3 = -0.4 \\
\theta_1 &= \theta_0 + m_0 = 1 - 0.4 = 0.6 \\
m_2 &= \beta\, m_1 - \eta\, g(\theta_1 + \beta\, m_1) = 0.9 \cdot (-0.4) - 0.1 \cdot 4 \cdot (0.6 + 0.9 \cdot (-0.4))^3 = -0.3655 \\
\theta_2 &= \theta_1 + m_1 = 0.6 - 0.3655 = 0.2345
\end{aligned}
$$

In [ ]:
```python
import numpy as np
def GD1d_momentum(g, x0, eta=0.1, beta=0.9, tol=1e-3, max_iter=2):
    x = x0; delta = np.inf; i = 0; m = np.zeros_like(x)
    while np.max(np.abs(delta)) > tol and i < max_iter:
        m = beta * m - eta * g(x + beta * m); x = x + m; i = i + 1
        print(f'm = {m:.4f} x = {x:.4f} f = {f(x):.4f}')
```

In [ ]:
```python
f = lambda t: np.power(t, 4); g = lambda t: 4 * np.power(t, 3); GD1d_momentum(g, 1)
```

```
m = -0.4000 x = 0.6000 f = 0.1296
m = -0.3655 x = 0.2345 f = 0.0030
```

6 Cálculo matricial

☐ El cálculo matricial es una notación especializada para manejar derivadas parciales con matrices. Sean $\boldsymbol{x} \in \mathbb{R}^3$ e $\boldsymbol{y} = \boldsymbol{f}(\boldsymbol{x}) \in \mathbb{R}^2$. De acuerdo con el formato numerador (que seguimos en la asignatura), la Jacobiana de $\boldsymbol{y}$ respecto de $\boldsymbol{x}$ es:

1. $\dfrac{\partial \boldsymbol{y}}{\partial \boldsymbol{x}} = \begin{bmatrix} \dfrac{\partial y_1}{\partial x_1} & \dfrac{\partial y_1}{\partial x_2} & \dfrac{\partial y_1}{\partial x_3} & \dfrac{\partial y_2}{\partial x_1} & \dfrac{\partial y_2}{\partial x_2} & \dfrac{\partial y_2}{\partial x_3} \end{bmatrix}$
2. $\dfrac{\partial \boldsymbol{y}}{\partial \boldsymbol{x}} = \begin{bmatrix} \dfrac{\partial y_1}{\partial x_1} & \dfrac{\partial y_1}{\partial x_2} & \dfrac{\partial y_1}{\partial x_3} \\ \dfrac{\partial y_2}{\partial x_1} & \dfrac{\partial y_2}{\partial x_2} & \dfrac{\partial y_2}{\partial x_3} \end{bmatrix}$
3. $\dfrac{\partial \boldsymbol{y}}{\partial \boldsymbol{x}} = \begin{bmatrix} \dfrac{\partial y_1}{\partial x_1} & \dfrac{\partial y_2}{\partial x_1} \\ \dfrac{\partial y_1}{\partial x_2} & \dfrac{\partial y_2}{\partial x_2} \\ \dfrac{\partial y_1}{\partial x_3} & \dfrac{\partial y_2}{\partial x_3} \end{bmatrix}$
4. Ninguna de las anteriores

Solución: La 2.

Problema: Sean $y = \boldsymbol{u}^t \mathbf{W} \boldsymbol{x},\ \boldsymbol{u} \in \mathbb{R}^m,\ \mathbf{W} \in \mathbb{R}^{m \times n},\ \boldsymbol{x} \in \mathbb{R}^n,\ m = 2,\ n = 3$. Prueba que $\dfrac{\partial y}{\partial \mathbf{W}} = \boldsymbol{x}\boldsymbol{u}^t$

Solución:

$$
\begin{aligned}
y &= (u_1, u_2) \begin{pmatrix} W_{11} & W_{12} & W_{13} \\ W_{21} & W_{22} & W_{23} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \\
&= (u_1 W_{11} + u_2 W_{21}, u_1 W_{12} + u_2 W_{22}, u_1 W_{13} + u_2 W_{23}) \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \\
&= u_1 W_{11} x_1 + u_2 W_{21} x_1 + u_1 W_{12} x_2 + u_2 W_{22} x_2 + u_1 W_{13} x_3 + u_2 W_{23} x_3 \\
\frac{\partial y}{\partial \mathbf{W}} &= \begin{pmatrix} \frac{\partial y}{\partial W_{11}} & \frac{\partial y}{\partial W_{21}} \\ \frac{\partial y}{\partial W_{12}} & \frac{\partial y}{\partial W_{22}} \\ \frac{\partial y}{\partial W_{13}} & \frac{\partial y}{\partial W_{23}} \end{pmatrix} = \begin{pmatrix} u_1 x_1 & u_2 x_1 \\ u_1 x_2 & u_2 x_2 \\ u_1 x_3 & u_2 x_3 \end{pmatrix} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} (u_1, u_2) = \boldsymbol{x}\boldsymbol{u}^t
\end{aligned}
$$

El desarrollo es válido para todo $m, n \geq 1$.

Problema: Sean $\boldsymbol{x} \in \mathbb{R}^n$, $\boldsymbol{y} = \boldsymbol{\varphi}(\boldsymbol{x}) \in \mathbb{R}^n$, $y_i = \varphi(x_i)$, $i = 1, \ldots, n$, con $\varphi(z) = \mathrm{ReLU}(z) = \max(z, 0)$, $\varphi'(z) = \mathrm{ReLU}'(z) = \mathbb{I}(z > 0)$. Prueba que

$$\frac{\partial \boldsymbol{y}}{\partial \boldsymbol{x}} = \mathrm{diag}(\mathbb{I}(x_1 > 0), \ldots, \mathbb{I}(x_n > 0))$$

Solución:

$$\boldsymbol{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} \varphi(x_1) \\ \varphi(x_2) \\ \vdots \\ \varphi(x_n) \end{bmatrix} \qquad \frac{\partial \boldsymbol{y}}{\partial \boldsymbol{x}} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_n}{\partial x_1} & \cdots & \frac{\partial y_n}{\partial x_n} \end{bmatrix} = \mathrm{diag}(\mathbb{I}(x_1 > 0), \ldots, \mathbb{I}(x_n > 0))$$

Problema: Sean $y = \boldsymbol{u}^t \boldsymbol{\varphi}(\boldsymbol{h})$, $\boldsymbol{h} = \mathbf{W}\boldsymbol{x}$, $\boldsymbol{u} \in \mathbb{R}^m$, $\boldsymbol{h} \in \mathbb{R}^m$, $\boldsymbol{\varphi} : \mathbb{R}^m \to \mathbb{R}^m$ tal que $\varphi_i = \varphi(x_i)$, $i = 1, \ldots, n$, con $\varphi : \mathbb{R} \to \mathbb{R}$ derivable, $\mathbf{W} \in \mathbb{R}^{m \times n}$, $\boldsymbol{x} \in \mathbb{R}^n$. Prueba que $\dfrac{\partial y}{\partial \mathbf{W}} = \boldsymbol{x}\,(\boldsymbol{u}^t \odot \boldsymbol{\varphi}'(\boldsymbol{h}))$ donde $\odot$ denota el producto Hadamard (elemental).

Solución:

$$\frac{\partial y}{\partial \mathbf{W}} = \boldsymbol{u}^t \frac{\partial \boldsymbol{\varphi}(\boldsymbol{h})}{\partial \boldsymbol{h}} \frac{\partial \boldsymbol{h}}{\partial \mathbf{W}} = (\boldsymbol{u}^t \odot \boldsymbol{\varphi}'(\boldsymbol{h})) \frac{\partial \boldsymbol{h}}{\partial \mathbf{W}} = \boldsymbol{x}\,(\boldsymbol{u}^t \odot \boldsymbol{\varphi}'(\boldsymbol{h}))$$