TA5 Actividades de análisis discriminante

1 Introducción

☐ Los clasificadores generativos básicos expresan **posteriors** en función de **priors** y **densidades condicionales** de las clases. En relación con ello, indica la expresión incorrecta o escoge la última opción si las tres primeras son correctas:

1. $p(y = c \mid \boldsymbol{x}, \boldsymbol{\theta}) = \dfrac{p(\boldsymbol{x}, y = c \mid \boldsymbol{\theta})}{p(\boldsymbol{x} \mid \boldsymbol{\theta})}$
2. $p(y = c \mid \boldsymbol{x}, \boldsymbol{\theta}) = \dfrac{p(\boldsymbol{x}, y = c \mid \boldsymbol{\theta})}{\sum_{c'} p(\boldsymbol{x}, y = c' \mid \boldsymbol{\theta})}$
3. $p(y = c \mid \boldsymbol{x}, \boldsymbol{\theta}) = \dfrac{p(\boldsymbol{x} \mid y = c, \boldsymbol{\theta})\, p(y = c, \boldsymbol{\theta})}{\sum_{c'} p(\boldsymbol{x} \mid y = c', \boldsymbol{\theta})\, p(y = c', \boldsymbol{\theta})}$
4. Las tres afirmaciones anteriores son correctas.

Solución: La 4.

☐ A continuación se describen algunas ventajas bien conocidas de los clasificadores generativos usuales. En relación con las mismas, indica la afirmación incorrecta o escoge la última opción si las tres primeras son correctas:

1. Son fáciles de ajustar.
2. Pueden extenderse a nuevas clases sin necesidad de re-entrenar parámetros ya entrenados.
3. Facilitan el tratamiento de datos perdidos.
4. Las tres afirmaciones anteriores son correctas.

Solución: La 4.

2 Análisis discriminante cuadrático (QDA)

Problema. Sea un problema de clasificación en $C = 2$ clases equiprobables de datos representados mediante vectores de $D = 2$ reales. Se tiene un clasificador QDA con condicionales de las clases

$$\begin{array}{lll} p(\boldsymbol{x} \mid y = 1, \boldsymbol{\theta}) = \mathcal{N}_D(\boldsymbol{x} \mid \boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1) & \boldsymbol{\mu}_1 = (0,0)^t & \boldsymbol{\Sigma}_1 = \mathbf{I} \\ p(\boldsymbol{x} \mid y = 2, \boldsymbol{\theta}) = \mathcal{N}_D(\boldsymbol{x} \mid \boldsymbol{\mu}_2, \boldsymbol{\Sigma}_2) & \boldsymbol{\mu}_2 = (2,0)^t & \boldsymbol{\Sigma}_2 = \mathrm{diag}(1/5, 1/4) \end{array}$$

La regla de decisión MAP induce una frontera de separación elíptica de centro $(c_1, c_2)^t$ y semiejes a y b:

$$\frac{(x_1 - c_1)^2}{a^2} + \frac{(x_2 - c_2)^2}{b^2} = 1$$

Determina el centro y semiejes de la frontera.

Solución.

$$\log p(y = c \mid \boldsymbol{x}, \boldsymbol{\theta}) \propto \boldsymbol{x}^t \mathbf{A}_c \boldsymbol{x} + \boldsymbol{\beta}_c^t \boldsymbol{x} + \gamma_c$$

$$\mathbf{A}_c = -\frac{1}{2}\boldsymbol{\Sigma}_c^{-1} \qquad \boldsymbol{\beta}_c = \boldsymbol{\Sigma}_c^{-1}\boldsymbol{\mu}_c \qquad \gamma_c = -\frac{1}{2}\log|\boldsymbol{\Sigma}_c| - \frac{1}{2}\boldsymbol{\mu}_c^t\boldsymbol{\Sigma}_c^{-1}\boldsymbol{\mu}_c$$

$$\mathbf{A}_1 = -\frac{1}{2}\mathbf{I} \qquad \boldsymbol{\beta}_1 = \mathbf{0} \qquad \gamma_1 = 0$$

$$\mathbf{A}_2 = -\frac{1}{2}\mathrm{diag}(5,4) \qquad \boldsymbol{\beta}_2 = (10,0)^t \qquad \gamma_2 = \frac{1}{2}\log 20 - 10 = -8.5$$

$$-\frac{1}{2}x_1^2 - \frac{1}{2}x_2^2 = -\frac{5}{2}x_1^2 - \frac{4}{2}x_2^2 + 10x_1 - 8.5$$

$$-x_1^2 - x_2^2 = -5x_1^2 - 4x_2^2 + 20x_1 - 17$$

$$4x_1^2 - 20x_1 + 3x_2^2 = -17$$

$$4(x_1^2 - 5x_1 + 25/4) - 25 + 3x_2^2 = -17$$

$$\frac{(x_1 - 5/2)^2}{1/4} + \frac{(x_2 - 0)^2}{1/3} = 8$$

$$\frac{(x_1 - 5/2)^2}{2} + \frac{(x_2 - 0)^2}{8/3} = 1$$

$$c_1 = 2.5 \qquad c_2 = 0 \qquad a = \sqrt{2} = 1.4142 \qquad b = \sqrt{8/3} = 1.6330$$

In [ ]:
```
import numpy as np; import matplotlib.pyplot as plt
m1 = np.zeros(2); S1 = np.eye(2); iS1 = np.linalg.inv(S1)
m2 = np.array([2, 0]); S2 = np.diag([.2, .25]); iS2 = np.linalg.inv(S2)
A1, b1, c1 = -0.5 * iS1, iS1 @ m1, -0.5 * np.log(np.linalg.det(S1)) - 0.5 * m1.T @ iS1 @ m1
A2, b2, c2 = -0.5 * iS2, iS2 @ m2, -0.5 * np.log(np.linalg.det(S2)) - 0.5 * m2.T @ iS2 @ m2
x1, x2 = np.meshgrid(np.linspace(-2, 4, 200), np.linspace(-2, 2, 200))
x = np.c_[np.ravel(x1), np.ravel(x2)]
p1 =  lambda x: x.T @ A1 @ x + b1 @ x + c1
p2 =  lambda x: x.T @ A2 @ x + b2 @ x + c2
maxp = lambda x: max(p1(x), p2(x))
maxpx = np.apply_along_axis(maxp, 1, x)
amaxp = lambda x: np.argmax([p1(x), p2(x)])
amaxpx = np.apply_along_axis(amaxp, 1, x);
```

In [ ]:
```
fig, ax = plt.subplots(1, 1, figsize=(6, 4)); ax.set(aspect='equal')
ax.contour(x1, x2, maxpx.reshape(x1.shape), 16, colors='orange', linestyles='solid')
cp = ax.contourf(x1, x2, maxpx.reshape(x1.shape), 16, cmap='Blues_r')
plt.colorbar(cp, ax=ax, shrink=0.8)
t = np.linspace(0, 2.0 * np.pi, 100)
elipse = np.array([1.4142 * np.cos(t) + 2.5, 1.633 * np.sin(t)]).T
ax.plot(elipse[:, 0], elipse[:, 1], color='black', lw=3);
#ax.contour(x1, x2, amaxpx.reshape(x1.shape), colors='white', linestyles='solid', linewidths=1);
```

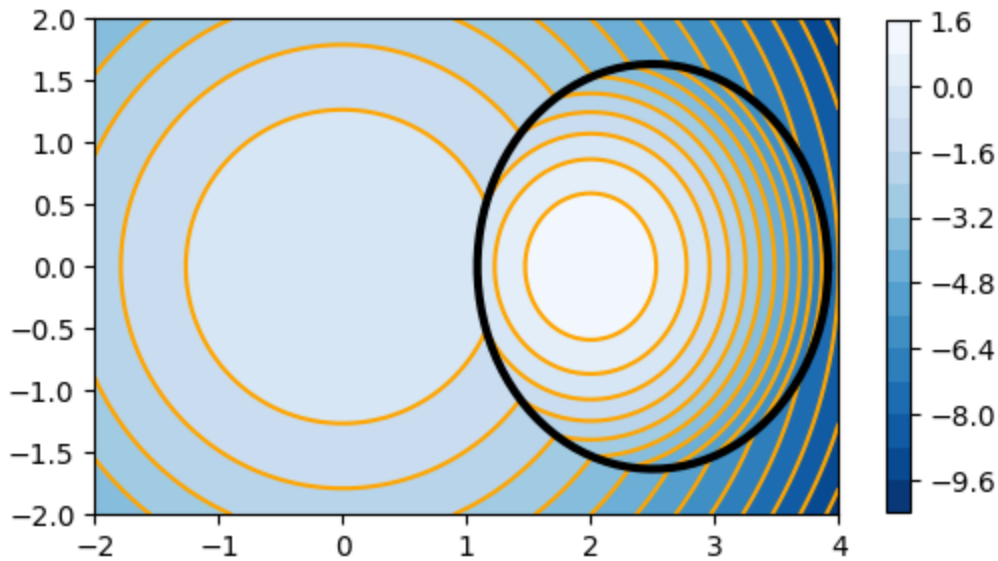

Problema. Sea un problema de clasificación en $C = 2$ clases equiprobables de datos representados mediante vectores de $D = 2$ reales. Se tiene un clasificador QDA con condicionales de las clases

$$\begin{array}{lll} p(\boldsymbol{x} \mid y = 1, \boldsymbol{\theta}) = \mathcal{N}_D(\boldsymbol{x} \mid \boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1) & \boldsymbol{\mu}_1 = (0,0)^t & \boldsymbol{\Sigma}_1 = \text{diag}(1, 1/9) \\ p(\boldsymbol{x} \mid y = 2, \boldsymbol{\theta}) = \mathcal{N}_D(\boldsymbol{x} \mid \boldsymbol{\mu}_2, \boldsymbol{\Sigma}_2) & \boldsymbol{\mu}_2 = (2,0)^t & \boldsymbol{\Sigma}_2 = \text{diag}(1/9, 1) \end{array}$$

La regla de decisión MAP induce una frontera de separación hiperbólica de centro $(c_1, c_2)^t$ y semiejes a y b:

$$\frac{(x_1 - c_1)^2}{a^2} - \frac{(x_2 - c_2)^2}{b^2} = 1$$

Determina el centro y semiejes de la frontera.

Solución.

$$\log p(y = c \mid \boldsymbol{x}, \boldsymbol{\theta}) \propto \boldsymbol{x}^t \mathbf{A}_c \boldsymbol{x} + \boldsymbol{\beta}_c^t \boldsymbol{x} + \gamma_c$$

$$\mathbf{A}_c = -\frac{1}{2}\boldsymbol{\Sigma}_c^{-1} \qquad \boldsymbol{\beta}_c = \boldsymbol{\Sigma}_c^{-1}\boldsymbol{\mu}_c \qquad \gamma_c = -\frac{1}{2}\log|\boldsymbol{\Sigma}_c| - \frac{1}{2}\boldsymbol{\mu}_c^t\boldsymbol{\Sigma}_c^{-1}\boldsymbol{\mu}_c$$

$$\mathbf{A}_1 = -\frac{1}{2}\text{diag}(1, 9) \qquad \boldsymbol{\beta}_1 = \mathbf{0} \qquad \gamma_1 = \frac{1}{2}\log 9 = 1.0986$$

$$\mathbf{A}_2 = -\frac{1}{2}\text{diag}(9, 1) \qquad \boldsymbol{\beta}_2 = (18, 0)^t \qquad \gamma_2 = \frac{1}{2}\log 9 - 18 = -16.9014$$

$$-\frac{1}{2}x_1^2 - \frac{9}{2}x_2^2 + 1.0986 = -\frac{9}{2}x_1^2 - \frac{1}{2}x_2^2 + 18x_1 - 16.9014$$

$$-x_1^2 - 9x_2^2 + 2.1972 = -9x_1^2 - x_2^2 + 36x_1 - 33.8028$$

$$8x_1^2 - 36x_1 - 8x_2^2 = -36$$

$$x_1^2 - 9/2\, x_1 - x_2^2 = -9/2$$

$$(x_1 - 9/4)^2 - 81/16 - x_2^2 = -9/2$$

$$(x_1 - 9/4)^2 - x_2^2 = 9/16$$

$$\frac{(x_1 - 9/4)^2}{9/16} - \frac{(x_2 - 0)^2}{9/16} = 1$$

$$c_1 = 9/4 \qquad c_2 = 0 \qquad a = b = \sqrt{9/16} = 3/4$$

In [ ]:
```
import numpy as np; import matplotlib.pyplot as plt
m1 = np.zeros(2);      S1 = np.diag([1, 1/9]); iS1 = np.linalg.inv(S1)
m2 = np.array([2, 0]); S2 = np.diag([1/9, 1]); iS2 = np.linalg.inv(S2)
A1, b1, c1 = -0.5 * iS1, iS1 @ m1, -0.5 * np.log(np.linalg.det(S1)) - 0.5 * m1.T @ iS1 @ m1
A2, b2, c2 = -0.5 * iS2, iS2 @ m2, -0.5 * np.log(np.linalg.det(S2)) - 0.5 * m2.T @ iS2 @ m2
x1, x2 = np.meshgrid(np.linspace(-2, 4, 200), np.linspace(-2, 2, 200))
x = np.c_[np.ravel(x1), np.ravel(x2)]
p1 =  lambda x: x.T @ A1 @ x + b1 @ x + c1
p2 =  lambda x: x.T @ A2 @ x + b2 @ x + c2
maxp = lambda x: max(p1(x), p2(x))
maxpx = np.apply_along_axis(maxp, 1, x)
amaxp = lambda x: np.argmax([p1(x), p2(x)])
amaxpx = np.apply_along_axis(amaxp, 1, x);
```

In [ ]:
```
fig, ax = plt.subplots(1, 1, figsize=(6, 4)); ax.set(aspect='equal')
ax.contour(x1, x2, maxpx.reshape(x1.shape), 16, colors='orange', linestyles='solid')
cp = ax.contourf(x1, x2, maxpx.reshape(x1.shape), 16, cmap='Blues_r')
plt.colorbar(cp, ax=ax, shrink=0.8)
t = np.linspace(-np.pi/2.8, np.pi/2.8, 100)
hiperbola1 = np.array([3/4 / np.cos(t) + 9/4, 3/4 * np.tan(t)]).T
ax.plot(hiperbola1[:, 0], hiperbola1[:, 1], color='black', lw=3);
t = np.linspace(-np.pi/2.6, np.pi/2.6, 100)
hiperbola2 = np.array([- 3/4 / np.cos(t) + 9/4, 3/4 * np.tan(t)]).T
ax.plot(hiperbola2[:, 0], hiperbola2[:, 1], color='black', lw=3);
#ax.contour(x1, x2, amaxpx.reshape(x1.shape), colors='white', linestyles='solid', linewidths=1);
```

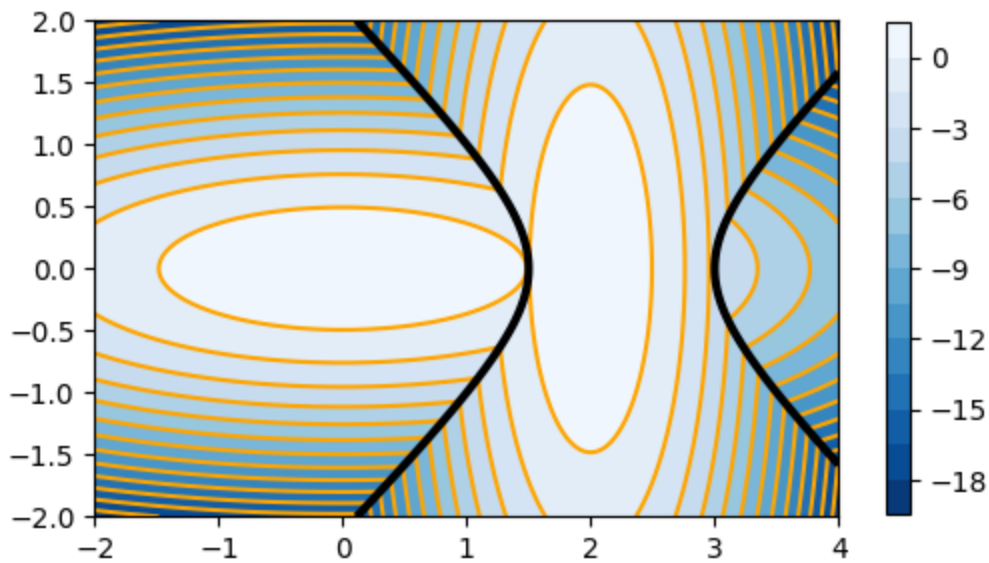

3 Análisis discriminante lineal (LDA)

☐ Indica la afirmación incorrecta o escoge la última opción si las tres primeras son correctas:

1. QDA asume que las densidades condicionales de las clases son Gaussianas independientes, lo que resulta en discriminantes (log-posteriors) cuadráticas.
2. LDA asume que las densidades condicionales de las clases son Gaussianas de matriz de covarianzas común, lo que resulta en discriminantes (log-posteriors) lineales.
3. QDA suele ajustarse con las medias empíricas de las clases y la matriz de covarianzas empírica global.
4. Las tres afirmaciones anteriores son correctas.

Solución: La 3. QDA suele ajustarse con las medias y matrices de covarianzas empíricas de las clases. LDA suele ajustarse con las medias empíricas de las clases y la matriz de covarianzas empírica global.

☐ **(PER 25-6-2024)** Con respecto al clasificador por el centroide más próximo, indica la opción correcta:

1. Asume distribuciones condicionales Gaussianas, con una media y una matriz de convarianzas para cada clase. La clasificación se realiza a la clase con la menor distancia Euclídea entre el punto $\boldsymbol{x}$ a clasificar y la media $\boldsymbol{\mu}_c$.
2. Asume distribuciones condicionales Gaussianas, con una media y una matriz de convarianzas para cada clase y priors idénticas. La clasificación se realiza a la clase con la menor distancia de Mahalanobis entre el punto $\boldsymbol{x}$ a clasificar y la media $\boldsymbol{\mu}_c$.
3. Asume distribuciones condicionales Gaussianas, con una media y una matriz de convarianzas para cada clase. La clasificación se realiza a la clase con la menor distancia distancia de Mahalanobis entre el punto $\boldsymbol{x}$ a clasificar y la media $\boldsymbol{\mu}_c$.
4. Asume distribuciones condicionales Gaussianas, con una media y una matriz de convarianzas para cada clase y priors idénticas. La clasificación se realiza a la clase con la menor distancia Euclídea entre el punto $\boldsymbol{x}$ a clasificar y la media $\boldsymbol{\mu}_c$.

Solución: La 2.

☐ Sea un problema de clasificación de objetos representados mediante vectores de $D = 2$ variables reales en $C = 3$ clases de probabilidades a priori idénticas. Se tiene un clasificador Gaussiano de densidades condicionales con matrices de covarianzas común:

$$p(\boldsymbol{x} \mid y = c, \boldsymbol{\theta}) = \mathcal{N}_D(\boldsymbol{\mu}_c, \boldsymbol{\Sigma}) \quad \text{donde} \quad \boldsymbol{\theta} = (\boldsymbol{\mu}_1, \ldots, \boldsymbol{\mu}_C, \mathrm{vec}(\boldsymbol{\Sigma}))^t$$

con

$$\boldsymbol{\mu}_1 = (0,0)^t, \qquad \boldsymbol{\mu}_2 = (0,4)^t, \qquad \boldsymbol{\mu}_3 = (4,4)^t \qquad \text{y} \qquad \boldsymbol{\Sigma} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

La región de decisión de la clase 2 es:

1. $\mathcal{R}_2 = \{\boldsymbol{x} : x_1 > 2,\ x_2 > 2\}$
2. $\mathcal{R}_2 = \{\boldsymbol{x} : x_1 > 2,\ x_2 < 2\}$
3. $\mathcal{R}_2 = \{\boldsymbol{x} : x_1 < 2,\ x_2 > 2\}$
4. $\mathcal{R}_2 = \{\boldsymbol{x} : x_1 < 2,\ x_2 < 2\}$

Solución: La 3. Discriminantes lineales simplificadas (ignorando términos aditivos independientes de c):

$$\log p(y = c \mid \boldsymbol{x}, \boldsymbol{\theta}) \propto g_c(\boldsymbol{x}) = \boldsymbol{\beta}_c^t \boldsymbol{x} + \gamma_c \qquad \text{con} \qquad \boldsymbol{\beta}_c = \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_c = \boldsymbol{\mu}_c \quad \text{y} \quad \gamma_c = -\frac{1}{2}\boldsymbol{\mu}_c^t \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_c = -\frac{1}{2}\boldsymbol{\mu}_c^t\boldsymbol{\mu}_c$$

$$\begin{aligned}
g_1(\boldsymbol{x}) &= \boldsymbol{\mu}_1^t \boldsymbol{x} - \frac{1}{2}\boldsymbol{\mu}_1^t\boldsymbol{\mu}_1 = 0 \\
g_2(\boldsymbol{x}) &= \boldsymbol{\mu}_2^t \boldsymbol{x} - \frac{1}{2}\boldsymbol{\mu}_2^t\boldsymbol{\mu}_2 = 4\,x_2 - 8 \\
g_3(\boldsymbol{x}) &= \boldsymbol{\mu}_3^t \boldsymbol{x} - \frac{1}{2}\boldsymbol{\mu}_3^t\boldsymbol{\mu}_3 = 4\,x_1 + 4\,x_2 - 16
\end{aligned}$$

$$\begin{aligned}
\mathcal{R}_2 &= \{\boldsymbol{x} : g_2(\boldsymbol{x}) > g_1(\boldsymbol{x}),\ g_2(\boldsymbol{x}) > g_3(\boldsymbol{x})\} \\
&= \{\boldsymbol{x} : 4\,x_2 - 8 > 0,\ 4\,x_2 - 8 > 4\,x_1 + 4\,x_2 - 16\} \\
&= \{\boldsymbol{x} : x_1 < 2,\ x_2 > 2\}
\end{aligned}$$