TA6 Actividades de regresión logística

1 Introducción

☐ A continuación se describen algunas ventajas bien conocidas de los clasificadores discriminativos usuales. En relación con las mismas, indica la afirmación incorrecta o escoge la última opción si las tres primeras son correctas:

1. Suelen ser más precisos que los generativos, con posteriors mejor calibradas.
2. Facilitan el preproceso de características, típicamente mediante expansión polinómica.
3. Las redes usuales pueden verse como extensiones de modelos discriminativos básicos.
4. Las tres afirmaciones anteriores son correctas.

Solución: La 4.

2 Regresión logística binaria

Problema. Sea un problema de clasificación en dos clases, $y \in \{0, 1\}$, y sea $p(y \mid \boldsymbol{x}; \boldsymbol{\theta}) = \mathrm{Ber}(y \mid \sigma(\boldsymbol{w}^t \boldsymbol{x} + b))$ un modelo de regresión logística binaria con $\boldsymbol{w} = (3, 3)^t$ y $b = 0$. Determina la probabilidad de que $\boldsymbol{x} = (0.5, 0.5)^t$ pertenezca a la clase 1 según el modelo dado.

Solución:

$$p(y = 1 \mid \boldsymbol{x}; \boldsymbol{\theta}) = \sigma(\boldsymbol{w}^t \boldsymbol{x} + b) = \sigma((3, 3)(0.5, 0.5)^t + 0) = \frac{1}{1 + e^{-3}} = 0.9526$$

Problema. Sea un problema de clasificación en dos clases, $y \in \{0, 1\}$, y sea $p(y \mid \boldsymbol{x}; \boldsymbol{\theta}) = \mathrm{Ber}(y \mid \sigma(\boldsymbol{w}^t \boldsymbol{x} + b))$ un modelo de regresión logística binaria con $\boldsymbol{w} = (3, 3)^t$ y $b = 0$. Determina la logit, $f(\boldsymbol{x}; \boldsymbol{\theta})$, así como la frontera y regiones de decisión que induce (con pérdida 0-1).

Solución:

Logit: $f(\boldsymbol{x}; \boldsymbol{\theta}) = b + \boldsymbol{w}^t \boldsymbol{x} = 3x_1 + 3x_2$

Frontera: $3x_1 + 3x_2 = 0 \to x_2 = -x_1$

Regiones de decisión:

$$\begin{aligned}
\mathcal{R}_1 &= \{\boldsymbol{x} : p(y = 1 \mid \boldsymbol{x}; \boldsymbol{\theta}) > p(y = 0 \mid \boldsymbol{x}; \boldsymbol{\theta})\} \\
&= \left\{\boldsymbol{x} : \frac{p(y = 1 \mid \boldsymbol{x}; \boldsymbol{\theta})}{p(y = 0 \mid \boldsymbol{x}; \boldsymbol{\theta})} > 1\right\} \\
&= \{\boldsymbol{x} : f(\boldsymbol{x}; \boldsymbol{\theta}) > 0\} \\
&= \{\boldsymbol{x} : 3x_1 + 3x_2 > 0\} \\
&= \{\boldsymbol{x} : x_2 > -x_1\} \\
\mathcal{R}_0 &= \{\boldsymbol{x} : x_2 < -x_1\}
\end{aligned}$$

☐ Sea $\mathcal{D} = \{(\boldsymbol{x}_n, y_n) : \boldsymbol{x}_n \in \mathbb{R}^D, y_n \in \{0,1\}\}$, un conjunto de muestras no linealmente separables. Se quiere aprender un modelo de clasificación $p(y \mid \boldsymbol{x}; \boldsymbol{\theta})$ que las clasifique con pérdida 01 nula. Indica la respuesta correcta:

1. Podemos usar regresión logística binaria convencional, esto es, con $p(y=1 \mid \boldsymbol{x}) = \mathrm{Ber}(y \mid \sigma(\boldsymbol{w}^t\boldsymbol{x} + b))$.
2. No podemos usar regresión logística binaria convencional, pero sí regresión logística binaria con una función de preproceso, $\phi(\boldsymbol{x})$, que linearice las muestras.
3. No podemos usar regresión logística binaria, convencional o no; necesitamos un modelo de clasificación multi-clase.
4. No podemos usar regresión logística binaria, convencional o no, pues es un modelo lineal y se necesita uno no lineal.

Solución: La 2; la 4 es falsa porque puede haber una función de preproceso que linearice las muestras.

Problema. Sea $p(y \mid \boldsymbol{x}; \boldsymbol{w}) = \mathrm{Ber}(y \mid \sigma(\boldsymbol{w}^t\boldsymbol{x}))$, $y \in \{0,1\}$, un modelo de regresión logística binaria en notación compacta (homogénea). Sea el conjunto de datos de entrenamiento $\mathcal{D} = \{(\boldsymbol{x}_n, y_n)\}$, donde $\boldsymbol{x}_n \in \mathbb{R}^D$ y $y_n \in \{0,1\}$. La entropía cruzada binaria de $\boldsymbol{w}$ es:

$$\mathcal{L}(\boldsymbol{w}) = \frac{1}{N}\sum_{n=1}^{N} \ell(y_n, \hat{y}_n) \quad \text{con} \quad \ell(y_n, \hat{y}_n) = -y_n \log \hat{y}_n - (1-y_n)\log(1-\hat{y}_n)$$

Demuestra que el gradiente (transpuesto) de la entropía cruzada binaria es:

$$\frac{\partial \mathcal{L}(\boldsymbol{w})}{\partial \boldsymbol{w}} = \frac{1}{N}\sum_{n=1}^{N} (\hat{y}_n - y_n)\, \boldsymbol{x}_n^t \quad \text{donde} \quad \hat{y}_n = \mu_n = \sigma(a_n) \quad \text{con logodds} \quad a_n = \boldsymbol{w}^t\boldsymbol{x}_n$$

Solución. Sabemos que la derivada de la entropía cruzada binaria (con un dato) respecto de la logodds es la predicción menos la referencia. Así pues:

$$\frac{\partial \mathcal{L}(\boldsymbol{w})}{\partial \boldsymbol{w}} = \frac{1}{N}\sum_{n} \frac{\partial \ell(y_n, \hat{y}_n)}{\partial a_n}\frac{\partial a_n}{\partial \boldsymbol{w}} = \frac{1}{N}\sum_{n} (\hat{y}_n - y_n)\boldsymbol{x}_n^t = \frac{1}{N}(\boldsymbol{\sigma}(\mathbf{X}\boldsymbol{w}) - \boldsymbol{y})^t\mathbf{X} \quad \text{con} \quad \boldsymbol{y} = (y_1, \ldots, y_N)^t$$

Problema. Sea $p(y \mid \boldsymbol{x}; \boldsymbol{w}) = \mathrm{Ber}(y \mid \sigma(\boldsymbol{w}^t\boldsymbol{x}))$, $y \in \{0,1\}$, un modelo de regresión logística binaria en notación compacta (homogénea). Sea el conjunto de datos de entrenamiento $\mathcal{D} = \{(\boldsymbol{x}_n, y_n)\}$, donde $\boldsymbol{x}_n \in \mathbb{R}^D$ y $y_n \in \{0,1\}$. Sabemos que el gradiente (transpuesto) de la entropía cruzada binaria es:

$$\frac{\partial \mathcal{L}(\boldsymbol{w})}{\partial \boldsymbol{w}} = \frac{1}{N}\sum_{n=1}^{N} (\hat{y}_n - y_n)\, \boldsymbol{x}_n^t \quad \text{donde} \quad \hat{y}_n = \mu_n = \sigma(a_n) \quad \text{con logodds} \quad a_n = \boldsymbol{w}^t\boldsymbol{x}_n$$

Supón que estamos aplicando SGD con minibatch de talla 1 para minimizar $\mathcal{L}(\boldsymbol{w})$. Más concretamente, nos hallamos en la iteración i con $\boldsymbol{w}_i = (-1, 0, -1)^t$, $\eta_i = 0.1$ y el minibatch actual únicamente incluye la muestra $\boldsymbol{x}_n = (1,1,1)^t$, de clase $y_n = 1$. Determina $\boldsymbol{w}_{i+1}$.

Solución:

$$p(y_n = 1 \mid \boldsymbol{x}_n; \boldsymbol{w}_i) = \hat{y}_n = \mu_n = \sigma(\boldsymbol{w}_t^t\boldsymbol{x}_n) = \sigma(-2) = \frac{1}{1+e^2} = 0.12$$

$$\begin{aligned}
\boldsymbol{w}_{i+1} &= \boldsymbol{w}_i - \eta_i\,(\hat{y}_n - y_n)\boldsymbol{x}_n \\
&= (-1,0,-1)^t + 0.1\,(1-0.12)(1,1,1)^t \\
&= (-1,0,-1)^t + 0.09\,(1,1,1)^t \\
&= (-0.91, 0.09, -0.91)^t
\end{aligned}$$

Problema (PER 9-4-2024). Sean los $N = 8$ datos de $D = 2$ dimensiones y $C = 2$ clases (0 y 1):

n	1	2	3	4	5	6	7	8
x_{n1}	1	0.5	0	0	-1	-0.5	0	0
x_{n2}	0	0	1	0.5	0	0	-1	-0.5
y_n	0	1	0	1	0	1	0	1

In [ ]:
```
import numpy as np; import matplotlib.pyplot as plt
X = np.array([[1, 0], [.5, 0], [0, 1], [0, .5], [-1, 0], [-.5, 0], [0, -1], [0, -.5]])
y = np.array([0, 1, 0, 1, 0, 1, 0, 1]); _, ax = plt.subplots(figsize=(1.5, 1.5)); ax.grid()
ax.set_xticks(np.unique(X[:, 0])); ax.set_yticks(np.unique(X[:, 1])); ax.tick_params(axis='both', labelsize=7)
ax.scatter(*X.T, c=y, s=16); ax.scatter(*X.T, facecolors='none', edgecolors='black', s=16);
```

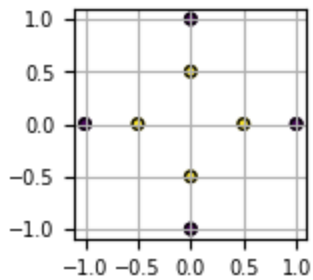

En vista de que los datos no son linealmente separables, se ha adoptado la siguiente función de preproceso:

$$\phi(x_1, x_2) = (1, x_1^2, x_2^2)$$

Con base en esta función, se ha considerado el siguiente modelo de regresión logística binaria:

$$p(y \mid \boldsymbol{x}, \boldsymbol{w}) = \mathrm{Ber}(y \mid \mu)$$

con $\mu = \sigma(a)$ y log-odds lineal con la entrada preprocesada, $a = \boldsymbol{w}^t \phi(\boldsymbol{x})$.

Se pide:

1. (0.5 puntos) Clasifica los datos por mínima probabilidad de error con $\boldsymbol{w} = (0.1, -0.3, 0)^t$.
2. (0.75 puntos) Con el fin de minimizar la neg-log-verosimilitud de $\boldsymbol{w}$ respecto a los datos, se ha aplicado descenso por gradiente estocástico con $\boldsymbol{w}_0 = \boldsymbol{0}$ y $\eta_i = \eta = 0.75$, procesando uno a uno los datos en el orden dado, hasta obtener $\boldsymbol{w}_7 = (-0.1331, -0.5026, -0.6453)^t$ tras la séptima iteración. Calcula $\boldsymbol{w}_8$ sabiendo que el gradiente de la neg-log-verosimilitud para un único dato, $\boldsymbol{x}_n$, es $\boldsymbol{g}_n = (\mu_n - y_n)\phi(\boldsymbol{x}_n)$.
3. (0.25 puntos) Halla la frontera entre las clases, en el espacio de representación original (2d), con $\boldsymbol{w}_8$.

Solución.

1. Clasificación de los datos por mínima probabilidad de error con $\boldsymbol{w} = (0.1, -0.3, 0)^t$:

$$y(\boldsymbol{x}) = \mathbb{I}(p(y=1 \mid \boldsymbol{x}) > p(y=0 \mid \boldsymbol{x})) = \mathbb{I}\left(\log \frac{p(y=1 \mid \boldsymbol{x})}{p(y=0 \mid \boldsymbol{x})} > 0\right) = \mathbb{I}(a > 0)$$

n	$\phi(\boldsymbol{x})^t$	a	$y(\boldsymbol{x}_n)$
1	$(1,1,0)$	$0.1 - 0.3 = -0.2$	0
2	$(1,0.25,0)$	$0.1 - 0.3 \cdot 0.25 = 0.025$	1
3	$(1,0,1)$	0.1	1
4	$(1,0,0.25)$	0.1	1
5	$(1,1,0)$	$0.1 - 0.3 = -0.2$	0
6	$(1,0.25,0)$	$0.1 - 0.3 \cdot 0.25 = 0.025$	1
7	$(1,0,1)$	0.1	1
8	$(1,0,0.25)$	0.1	1

2. Cálculo de $\boldsymbol{w}_8$:

$$\begin{aligned} a_8 &= \boldsymbol{w}_7^t \phi(\boldsymbol{x}_8) = (-0.1331, -0.5026, -0.6453)(1, 0, 0.25)^t \\ &= -0.1331 - 0.1613 = -0.2944 \end{aligned}$$

$$\mu_8 = \sigma(-0.2944) = \frac{1}{1 + e^{0.2944}} = 0.4269$$

$$\boldsymbol{g}_8 = (\mu_8 - y_8)\phi(\boldsymbol{x}_8) = (0.4269 - 1)(1, 0, 0.25)^t = (-0.5731, 0, -0.1433)^t$$

$$\begin{aligned} \boldsymbol{w}_8 &= \boldsymbol{w}_7 - \eta \boldsymbol{g}_8 = (-0.1331, -0.5026, -0.6453)^t - 0.75\,(-0.5731, 0, -0.1433)^t \\ &= (0.2967, -0.5026, -0.5378)^t \end{aligned}$$

3. La frontera es, aproximadamente, una circunferencia centrada en el origen de radio 0.75:

$$\begin{gathered} \boldsymbol{w}_8^t \phi(\boldsymbol{x}) = 0 \\ (0.2967, -0.5026, -0.5378)(1, x_1^2, x_2^2) = 0 \\ 0.5026 \cdot x_1^2 + 0.5378 \cdot x_2^2 = 0.2967 \\ \frac{x_1^2}{r_1^2} + \frac{x_2^2}{r_2^2} = 1 \quad \text{con} \quad r_1 = \sqrt{\frac{0.2967}{0.5026}} = 0.7683 \quad \text{y} \quad r_2 = \sqrt{\frac{0.2967}{0.5378}} = 0.7428 \end{gathered}$$

Preparación del problema y solución a máquina.

In [ ]:
```
# phi = lambda x: np.array([1.0, x[0], x[1], x[0]**2, x[1]**2])
phi = lambda x: np.array([1.0, x[0]**2, x[1]**2])
Xp = np.apply_along_axis(phi, 1, X); D = Xp.shape[1]
```

In [ ]:
```
N = 8; w, eta = np.zeros((9, D)), 0.75
for i in range(8):
    n = i % N
    mun = 1.0 / (1.0 + np.exp(- w[i, :] @ Xp[n, :]))
    grad = mun - y[n]
    w[i+1, :] = w[i, :] - eta * (mun - y[n]) * Xp[n, :]
    print(i+1, w[i+1])
```

```
1 [-0.375 -0.375  0.   ]
2 [ 0.08631589 -0.25967103  0.        ]
3 [-0.3048583  -0.25967103 -0.39117419]
4 [ 0.14463517 -0.25967103 -0.27880082]
5 [-0.20881936 -0.61312556 -0.27880082]
6 [ 0.23334229 -0.50258515 -0.27880082]
7 [-0.1331357  -0.50258515 -0.64527881]
8 [ 0.2966792  -0.50258515 -0.53782509]
```

In [ ]:
```
x_min, x_max = ax.get_xlim(); y_min, y_max = ax.get_ylim()
xx, yy = np.meshgrid(np.linspace(x_min, x_max, 100), np.linspace(y_min, y_max, 100))
XX = np.c_[np.ravel(xx), np.ravel(yy)]
fig, axes = plt.subplots(2, 4, figsize=(12, 6), constrained_layout=True)
for i in range(8):
    ax = axes.flat[i]; ax.axis('off'); ax = fig.add_subplot(2, 4, i + 1)
    ax.grid(); ax.set(aspect='equal')
    z = lambda x: w[i + 1, :] @ phi(x)
    zz = np.heaviside(np.apply_along_axis(z, 1, XX), 0.0)
    ax.contour(xx, yy, zz.reshape(xx.shape), 1, colors='orange', linestyles='solid')
    cp = ax.contourf(xx, yy, zz.reshape(xx.shape), 1, cmap='Blues')
    ax.scatter(*X.T, c=y, s=64); n = i % N
    ax.scatter(X[n, 0], X[n, 1], facecolors='none', edgecolors='red', s=80)
```

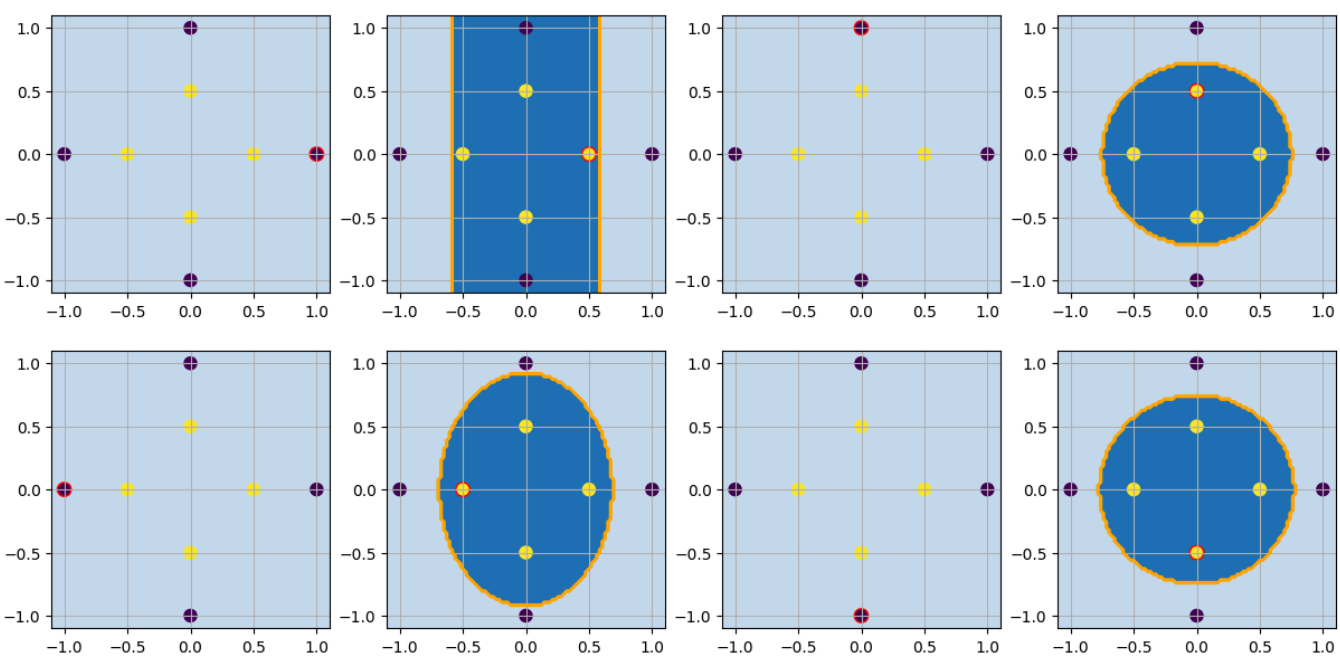

Problema (PER 25-6-2024). Sean los $N = 8$ datos de $D = 2$ dimensiones y $C = 2$ clases (0 y 1):

n	1	2	3	4	5	6	7	8
x_{n1}	-1	-0.5	0	0	0	0	0.5	1
x_{n2}	0	0	-1	-0.5	0.5	1	0	0
y_n	1	1	0	0	0	0	1	1

In [ ]:
```
import numpy as np; import matplotlib.pyplot as plt
X = np.array([[-1, 0], [-.5, 0], [0, -1], [0, -.5], [0, .5], [0, 1], [.5, 0], [1, 0]])
y = np.array([1, 1, 0, 0, 0, 0, 1, 1]); _, ax = plt.subplots(figsize=(1.5, 1.5)); ax.grid()
ax.set_xticks(np.unique(X[:, 0])); ax.set_yticks(np.unique(X[:, 1])); ax.tick_params(axis='both', labelsize=7)
ax.scatter(*X.T, c=y, s=16); ax.scatter(*X.T, facecolors='none', edgecolors='black', s=16);
```

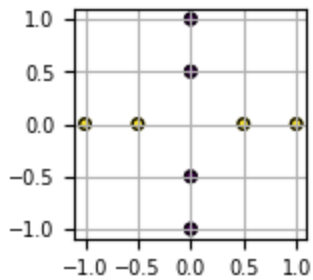

En vista de que los datos no son linealmente separables, se ha adoptado la siguiente función de preproceso:

$$\phi(x_1, x_2) = (1, x_1^2, x_2^2)$$

Con base en esta función, se ha considerado el siguiente modelo de regresión logística binaria:

$$p(y \mid \boldsymbol{x}, \boldsymbol{w}) = \mathrm{Ber}(y \mid \mu)$$

con $\mu = \sigma(a)$ y log-odds lineal con la entrada preprocesada, $a = \boldsymbol{w}^t \phi(\boldsymbol{x})$.

Se pide:

1. (0.5 puntos) Clasifica los datos por mínima probabilidad de error con $\boldsymbol{w} = (-0.2, 0.4, -0.6)^t$.
2. (0.75 puntos) Con el fin de minimizar la neg-log-verosimilitud de $\boldsymbol{w}$ respecto a los datos, se ha aplicado descenso por gradiente estocástico con $\boldsymbol{w}_0 = \boldsymbol{0}$ y $\eta_i = \eta = 0.75$, procesando uno a uno los datos en el orden dado, hasta obtener $\boldsymbol{w}_7 = (-0.2157, 0.5676, -0.8427)^t$ tras la séptima iteración. Calcula $\boldsymbol{w}_8$ sabiendo que el gradiente de la neg-log-verosimilitud para un único dato, $\boldsymbol{x}_n$, es $\boldsymbol{g}_n = (\mu_n - y_n)\phi(\boldsymbol{x}_n)$.
3. (0.25 puntos) Halla la frontera entre las clases, en el espacio de representación original (2d), con $\boldsymbol{w}_8$.

Solución.

1. Clasificación de los datos por mínima probabilidad de error con $\boldsymbol{w} = (-0.2, 0.4, -0.6)^t$.

$$y(\boldsymbol{x}) = \mathbb{I}(p(y=1 \mid \boldsymbol{x}) > p(y=0 \mid \boldsymbol{x})) = \mathbb{I}\left(\log \frac{p(y=1 \mid \boldsymbol{x})}{p(y=0 \mid \boldsymbol{x})} > 0\right) = \mathbb{I}(a > 0)$$

n	$\phi(\boldsymbol{x})^t$	a	$y(\boldsymbol{x}_n)$
1	$(1,1,0)$	$-0.2 + 0.4 = 0.2$	1
2	$(1,0.25,0)$	$-0.2 + 0.4 \cdot 0.25 = -0.1$	0
3	$(1,0,1)$	$-0.2 - 0.6 = -0.8$	0
4	$(1,0,0.25)$	$-0.2 - 0.6 \cdot 0.25 = -0.35$	0
5	$(1,0,0.25)$	-0.35	0
6	$(1,0,1)$	-0.8	0
7	$(1,0.25,0)$	-0.1	0
8	$(1,1,0)$	0.2	1

2. Cálculo de $\boldsymbol{w}_8$:

$$\begin{aligned} a_8 &= \boldsymbol{w}_7^t \phi(\boldsymbol{x}_8) = (-0.2157, 0.5676, -0.8427)(1,1,0)^t \\ &= -0.2157 + 0.5676 = 0.3519 \end{aligned}$$

$$\mu_8 = \sigma(0.3519) = \frac{1}{1+e^{-0.3519}} = 0.5871$$

$$\boldsymbol{g}_8 = (\mu_8 - y_8)\phi(\boldsymbol{x}_8) = (0.5871 - 1)(1,1,0)^t = (-0.4129, -0.4129, 0)^t$$

$$\boldsymbol{w}_8 = \boldsymbol{w}_7 - \eta \boldsymbol{g}_8 = (-0.2157, 0.5676, -0.8427)^t - 0.75\,(-0.4129, -0.4129, 0)^t = (0.0940, 0.8773, -0.8427)^t$$

3. La frontera es una hipérbola vertical centrada en el origen, vértices $(0, \pm a)$ y focos $(0, \pm c), c = \sqrt{a^2+b^2} = 0.47$

$$\begin{gathered} \boldsymbol{w}_8^t \phi(\boldsymbol{x}) = 0 \\ (0.0940, 0.8773, -0.8427)(1, x_1^2, x_2^2)^t = 0 \\ -0.8773\, x_1^2 + 0.8427\, x_2^2 = 0.0940 \\ \frac{x_2^2}{a^2} - \frac{x_1^2}{b^2} = 1 \quad \text{con} \quad a = \sqrt{\frac{0.0940}{0.8427}} = 0.3340 \quad \text{y} \quad b = \sqrt{\frac{0.0940}{0.8773}} = 0.3273 \end{gathered}$$

Preparación del problema y solución a máquina.

In [ ]:
```
# phi = lambda x: np.array([1.0, x[0], x[1], x[0]**2, x[1]**2])
phi = lambda x: np.array([1.0, x[0]**2, x[1]**2])
Xp = np.apply_along_axis(phi, 1, X); D = Xp.shape[1]
```

In [ ]:
```
N = 8; w, eta = np.zeros((9, D)), 0.75
for i in range(8):
    n = i % N
    mun = 1.0 / (1.0 + np.exp(- w[i, :] @ Xp[n, :]))
    grad = mun - y[n]
    w[i+1, :] = w[i, :] - eta * (mun - y[n]) * Xp[n, :]
    print(i+1, w[i+1])
```

```
1 [0.375 0.375 0.   ]
2 [0.66368411 0.44717103 0.        ]
3 [ 0.16861849  0.44717103 -0.49506561]
4 [-0.21478986  0.44717103 -0.5909177 ]
5 [-0.52255225  0.44717103 -0.6678583 ]
6 [-0.69744139  0.44717103 -0.84274744]
7 [-0.2156668   0.56761467 -0.84274744]
8 [ 0.09401581  0.87729728 -0.84274744]
```

In [ ]:
```
x_min, x_max = ax.get_xlim(); y_min, y_max = ax.get_ylim()
xx, yy = np.meshgrid(np.linspace(x_min, x_max, 100), np.linspace(y_min, y_max, 100))
XX = np.c_[np.ravel(xx), np.ravel(yy)]
fig, axes = plt.subplots(2, 4, figsize=(12, 6), constrained_layout=True)
for i in range(8):
    ax = axes.flat[i]; ax.axis('off'); ax = fig.add_subplot(2, 4, i + 1)
    ax.grid(); ax.set(aspect='equal')
    z = lambda x: w[i + 1, :] @ phi(x)
    zz = np.heaviside(np.apply_along_axis(z, 1, XX), 0.0)
    ax.contour(xx, yy, zz.reshape(xx.shape), 1, colors='orange', linestyles='solid')
    cp = ax.contourf(xx, yy, zz.reshape(xx.shape), 1, cmap='Blues')
    ax.scatter(*X.T, c=y, s=64); n = i % N
    ax.scatter(X[n, 0], X[n, 1], facecolors='none', edgecolors='red', s=80)
```

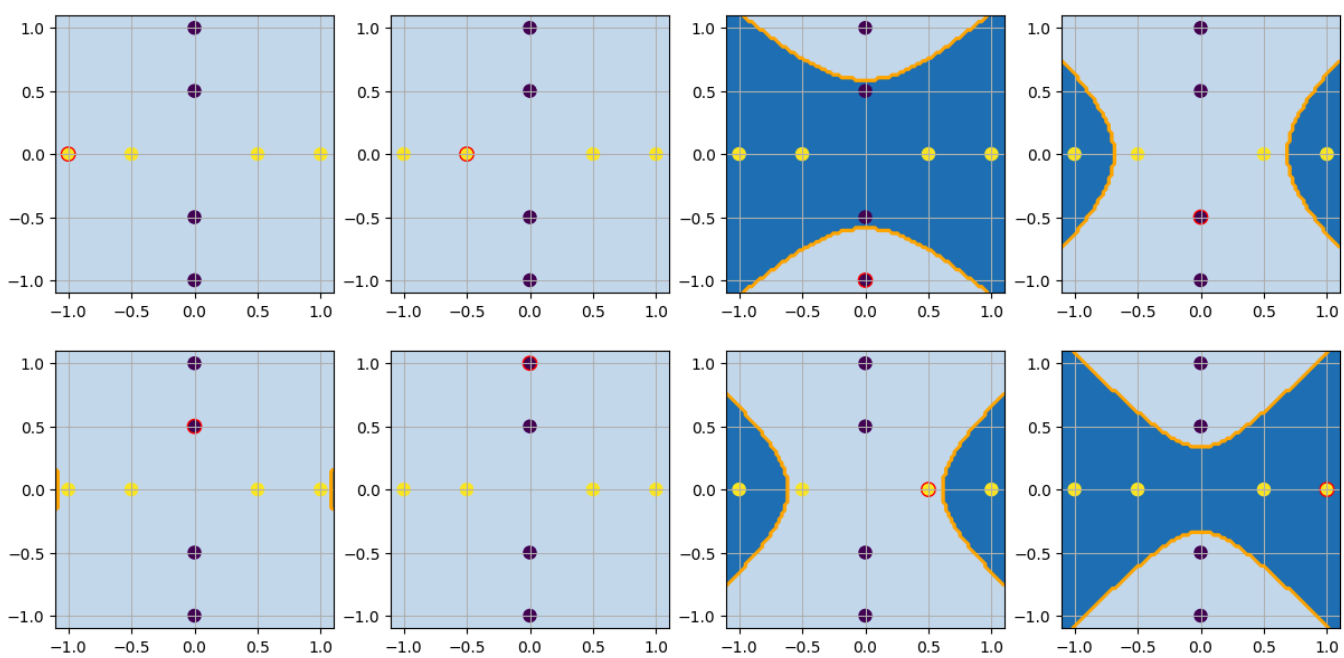

3 Regresión logística

Problema. Sea un problema de clasificación en $C = 3$ clases, $y \in \{1, 2, 3\}$, y sea el modelo de regresión logística

$$p(y \mid \boldsymbol{x}; \mathbf{W}) = \mathrm{Cat}(y \mid \mathcal{S}(\mathbf{W}^t \boldsymbol{x})) \quad \text{con} \quad \mathbf{W} = \begin{pmatrix} 1 & -1 & 0 \\ 1 & 1 & 0 \end{pmatrix}$$

Determina la probabilidad de que $\boldsymbol{x} = (0.5, 0.5)^t$ pertenezca a la clase 1.

Solución:

$$\boldsymbol{a} = \mathbf{W}^t \boldsymbol{x} = \begin{pmatrix} 1 & 1 \\ -1 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$$

$$p(y = 1 \mid \boldsymbol{x}; \boldsymbol{\theta}) = \mathcal{S}(\boldsymbol{a})_1 = \frac{e^1}{e^0 + e^0 + e^1} = \frac{e}{1 + 1 + e} = \frac{1}{1 + 2/e} = 0.5761$$

☐ Sea un problema de clasificación de objetos representados mediante vectores de $D = 2$ reales, $\boldsymbol{x} \in \mathbb{R}^D$, en $C = 3$ clases, $y \in \{1, 2, 3\}$. Se tiene un modelo de regresión logística sin sesgo ($\boldsymbol{b} = \mathbf{0}$),

$$p(y \mid \boldsymbol{x}, \boldsymbol{\theta}) = \mathrm{Cat}(y \mid \boldsymbol{\mu}) \quad \text{con} \quad \boldsymbol{\mu} = \mathcal{S}(\boldsymbol{a}), \quad \boldsymbol{a} = \mathbf{W}^t \boldsymbol{x} \quad \text{y} \quad \mathbf{W} = \begin{pmatrix} 1 & 2 & 0 \\ 1 & 1 & 0 \end{pmatrix}$$

La probabilidad P de que $\boldsymbol{x} = (0.5, 0.5)^t$ pertenezca a la clase 1 es:

1. $0.00 \leq P < 0.25$
2. $0.25 \leq P < 0.50$
3. $0.50 \leq P < 0.75$
4. $0.75 \leq P \leq 1.00$

Solución: La 2.

$$\boldsymbol{a} = \mathbf{W}^t \boldsymbol{x} = \begin{pmatrix} 1 & 1 \\ 2 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix} = \begin{pmatrix} 1 \\ 1.5 \\ 0 \end{pmatrix}$$

$$P = p(y = 1 \mid \boldsymbol{x}, \boldsymbol{\theta}) = \mathcal{S}(\boldsymbol{a})_1 = \frac{e^1}{e^1 + e^{1.5} + e^0} = \frac{e}{8.2} = 0.3315$$

Problema. Sea $p(y \mid \boldsymbol{x}; \mathbf{W}) = \mathrm{Cat}(y \mid \mathcal{S}(\mathbf{W}^t\boldsymbol{x}))$, $y \in \{1,2,3\}$, un modelo de regresión logística en notación homogénea. Sea el conjunto de datos de entrenamiento $\mathcal{D} = \{(\boldsymbol{x}_n, \boldsymbol{y}_n)\}$, donde $\boldsymbol{x}_n \in \mathbb{R}^D$ y $\boldsymbol{y}_n \in \{0,1\}^3$ (onehot). La entropía cruzada de $\mathbf{W}$ es:

$$\mathcal{L}(\mathbf{W}) = \frac{1}{N}\sum_{n=1}^{N} \ell(\boldsymbol{y}_n, \hat{\boldsymbol{y}}_n) \quad \text{con} \quad \ell(\boldsymbol{y}_n, \hat{\boldsymbol{y}}_n) = -\sum_c y_{nc} \log \hat{y}_{nc}$$

Demuestra que la Jacobiana de la entropía cruzada es:

$$\frac{\partial \mathcal{L}(\mathbf{W})}{\partial \mathbf{W}} = \frac{1}{N}\sum_{n=1}^{N} \boldsymbol{x}_n(\hat{\boldsymbol{y}}_n - \boldsymbol{y}_n)^t \quad \text{donde} \quad \hat{\boldsymbol{y}}_n = \boldsymbol{\mu}_n = \mathcal{S}(\boldsymbol{a}_n) \quad \text{con logits} \quad \boldsymbol{a}_n = \mathbf{W}^t\boldsymbol{x}_n$$

Solución. Sabemos que la Jacobiana de la entropía cruzada (con un dato) respecto de los logits es la (transpuesta de la) predicción menos la referencia. Así pues:

$$\frac{\partial \mathcal{L}(\mathbf{W})}{\partial \mathbf{W}} = \frac{1}{N}\sum_n \frac{\partial \ell(\boldsymbol{y}_n, \hat{\boldsymbol{y}}_n)}{\partial \hat{\boldsymbol{y}}_n}\frac{\partial \hat{\boldsymbol{y}}_n}{\partial \mathbf{W}} = \frac{1}{N}\sum_n (\hat{\boldsymbol{y}}_n - \boldsymbol{y}_n)^t \frac{\partial \hat{\boldsymbol{y}}_n}{\partial \mathbf{W}} = \frac{1}{N}\sum_n \boldsymbol{x}_n(\hat{\boldsymbol{y}}_n - \boldsymbol{y}_n)^t$$

Notación matricial: con $\mathbf{Y} = (\boldsymbol{y}_1, \ldots, \boldsymbol{y}_N)^t$ y aplicando la softmax por filas

$$\frac{\partial \mathcal{L}(\mathbf{W})}{\partial \mathbf{W}} = \frac{1}{N}(\boldsymbol{\mathcal{S}}(\mathbf{X}\mathbf{W}) - \mathbf{Y})^t\mathbf{X}$$

Problema. Sea $p(y \mid \boldsymbol{x}; \mathbf{W}) = \mathrm{Cat}(y \mid \mathcal{S}(\mathbf{W}^t\boldsymbol{x}))$, $y \in \{1,2,3\}$, un modelo de regresión logística en notación homogénea. Sea el conjunto de datos de entrenamiento $\mathcal{D} = \{(\boldsymbol{x}_n, \boldsymbol{y}_n)\}$, donde $\boldsymbol{x}_n \in \mathbb{R}^D$ y $\boldsymbol{y}_n \in \{0,1\}^3$ (onehot). Sabemos que la Jacobiana de la entropía cruzada es:

$$\frac{\partial \mathcal{L}(\mathbf{W})}{\partial \mathbf{W}} = \frac{1}{N}\sum_{n=1}^{N} \boldsymbol{x}_n(\hat{\boldsymbol{y}}_n - \boldsymbol{y}_n)^t \quad \text{donde} \quad \hat{\boldsymbol{y}}_n = \boldsymbol{\mu}_n = \mathcal{S}(\boldsymbol{a}_n) \quad \text{con logits} \quad \boldsymbol{a}_n = \mathbf{W}^t\boldsymbol{x}_n$$

Supón que estamos aplicando SGD con minibatch de talla 1 para minimizar $\mathcal{L}(\mathbf{W})$. Más concretamente, nos hallamos en la iteración i con la la muestra $\boldsymbol{x}_n = (1,1,1)^t$, de clase $y_n = 1$, factor de aprendizaje $\eta_i = 0.1$ y

$$\mathbf{W}_i = \begin{pmatrix} 1 & 0 & 1 \\ -1 & 1 & -1 \\ 0 & 0 & 1 \end{pmatrix}$$

Determina $\mathbf{W}_{i+1}$.

Solución:

$$\boldsymbol{a}_n = \mathbf{W}_i^t\boldsymbol{x}_n = \begin{pmatrix} 1 & -1 & 0 \\ 0 & 1 & 0 \\ 1 & -1 & 1 \end{pmatrix}\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} \qquad \boldsymbol{\mu}_n = S(\boldsymbol{a}_n) = \frac{1}{1+2e}\begin{pmatrix} 1 \\ e \\ e \end{pmatrix} = \begin{pmatrix} 0.1554 \\ 0.4223 \\ 0.4223 \end{pmatrix}$$

$$\mathbf{W}_{i+1} = \mathbf{W}_i - \eta_i\boldsymbol{x}_n(\boldsymbol{\mu}_n - \boldsymbol{y}_n)^t = \begin{pmatrix} 1 & 0 & 1 \\ -1 & 1 & -1 \\ 0 & 0 & 1 \end{pmatrix} - 0.1\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}(-0.8446, 0.4223, 0.4223)$$

$$= \begin{pmatrix} 1 & 0 & 1 \\ -1 & 1 & -1 \\ 0 & 0 & 1 \end{pmatrix} - \begin{pmatrix} -0.0845 & 0.0422 & 0.0422 \\ -0.0845 & 0.0422 & 0.0422 \\ -0.0845 & 0.0422 & 0.0422 \end{pmatrix} = \begin{pmatrix} 1.0845 & -0.0422 & 0.9578 \\ -0.9155 & 0.9578 & -1.0422 \\ 0.0845 & -0.0422 & 0.9578 \end{pmatrix}$$