T4 Probabilidad, estadística y decisión

Índice

1. Introducción
2. Distribución de Bernoulli
3. Distribución categórica
4. Distribución Gaussiana
5. Entropía
6. Estimación máximo-verosímil (MLE)
7. Minimización del riesgo empírico (ERM)
8. Regularización
9. Decisión

1 Introducción

Objetivo principal: sentar las bases en probabilidad, estadística y teoría de la decisión para aprendizaje automático

Distribuciones de probabilidad: modelos probabilísticos

- **Bernoulli:** clasificación binaria
- **Categórica:** clasificación multiclase
- **Gaussiana 1d:** regresión
- **Gaussiana (multivariada):** usada en múltiples técnicas

Entropía (cruzada): concepto clave para entender los criterios de entrenamiento usuales

Estimación máximo-verosímil (MLE): aproximación convencional del aprendizaje estadístico

Minimización del riesgo empírico (ERM): generalización del MLE usual en aprendizaje automático

Regularización: técnicas para evitar el sobre-entrenamiento de modelos

Decisión: teoría para usar los modelos entrenados de forma óptima

2 Distribución de Bernoulli

Distribución de Bernoulli: $Y \sim \mathrm{Ber}(\theta)$, $\theta \in [0,1]$, si su pmf $p : \{0,1\} \to [0,1]$ es

$$p(y \mid \theta) = \begin{cases} 1-\theta & \text{si } y = 0 \\ \theta & \text{si } y = 1 \end{cases} = \theta\, y + (1-\theta)(1-y) = \theta^y (1-\theta)^{1-y} \qquad (0^0 = 1,\ 0 \log 0 = 0)$$

- Y es el resultado de un **experimento** con probabilidad de **éxito** $(Y = 1)$ θ y probabilidad de **fracaso** $(Y = 0)$ $1 - \theta$

Ejemplo: $\theta = 0.25$

In [ ]:
```
import numpy as np; import matplotlib.pyplot as plt; from scipy.stats import bernoulli
t = 0.25; Y = bernoulli(t); print(Y.rvs(10)); y = (0, 1)
fig = plt.subplots(figsize=(3, 3)); plt.xticks(y); plt.bar(y, Y.pmf(y));
```

```
[0 0 0 0 1 0 0 0 0 1]
```

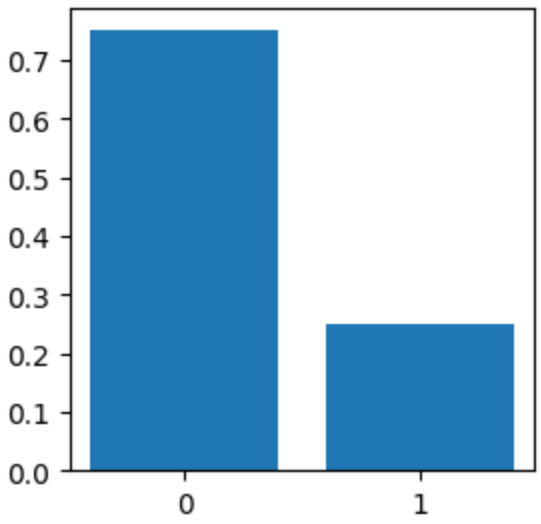

Función sigmoide: función $\sigma : \mathbb{R} \to [0, 1]$ con forma de S

$$\sigma(a) = \frac{1}{1 + e^{-a}} = \frac{e^a}{1 + e^a}$$

In [ ]:
```
import numpy as np; import matplotlib.pyplot as plt
def sigmoid(a):
        return 1 / (1 + np.exp(-a))
fig = plt.subplots(figsize=(2.75, 2.75)); plt.grid(); plt.yticks(np.arange(0, 1.1, step=0.25))
a = np.linspace(-5, 5, 200); plt.plot(a, sigmoid(a), linewidth=2);
```

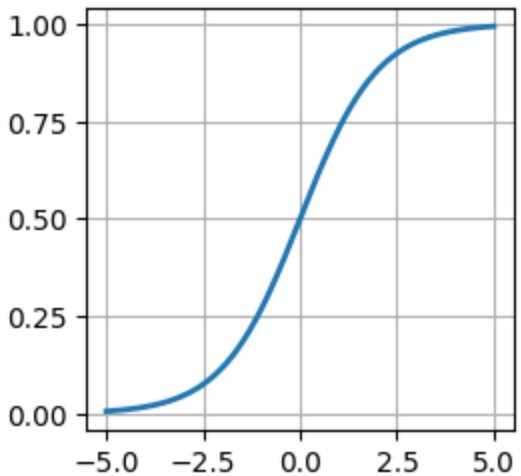

Propiedad:

$$1 - \sigma(a) = 1 - \frac{1}{1 + e^{-a}} = \frac{e^{-a}}{1 + e^{-a}} = \frac{1}{1 + e^a} = \sigma(-a)$$

Función logit: función $\mathrm{logit} : [0,1] \to \mathbb{R}$ inversa de la sigmoide, $\mathrm{logit}(p) = \log\left(\dfrac{p}{1-p}\right)$

Interpretación: si p es la probabilidad de que un cierto evento ocurra, su logit es la log-posibilidad (log-odds) de que el evento ocurra frente a que no ocurra, por lo que tenemos tres casos

1. Más posibilidades de ocurrir que de no: odds mayor que 1 y log-odds positiva
2. Igual posibilidades de ocurrir que de no: odds 1 y log-odds nula
3. Menos posibilidades de ocurrir que de no: odds menor que 1 y log-odds negativa

Inversa de la sigmoide: $\mathrm{logit}(\sigma(a)) = \log\left(\dfrac{\sigma(a)}{1-\sigma(a)}\right) = \log\left(\dfrac{e^a}{1+e^a}\dfrac{1+e^a}{1}\right) = \log(e^a) = a$

In [ ]:
```
import numpy as np; import matplotlib.pyplot as plt
def logit(p):
        return np.log(p / (1 - p))
fig = plt.subplots(figsize=(2.75, 2.75)); plt.grid(); plt.xticks(np.arange(0, 1.1, step=0.25))
p = np.linspace(.001, .999, 200); plt.plot(p, logit(p), linewidth=2);
```

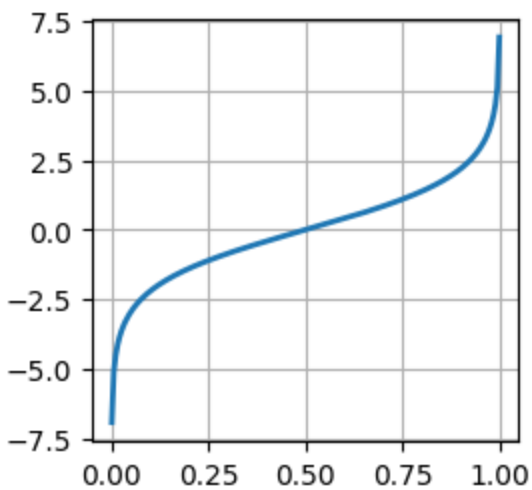

Recordatorio: **la sigmoide transforma log-odds en probabilidad y la logit probabilidad en log-odds**

3 Distribución categórica

Propósito: modelizar una distribución sobre un conjunto finito de etiquetas $\mathcal{C} = \{1, \ldots, C\}$, $C \geq 2$

Codificación one-hot: $y \in \mathcal{C}, \quad \text{one-hot}(y) = \boldsymbol{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_C \end{pmatrix} = \begin{pmatrix} \mathbb{I}(y=1) \\ \vdots \\ \mathbb{I}(y=C) \end{pmatrix} \in \{0,1\}^C \quad \text{con} \quad \sum_c y_c = 1$

Distribución categórica: $Y \sim \text{Cat}(\boldsymbol{\theta})$, $\boldsymbol{\theta} \in [0,1]^C$, $\sum_c \theta_c = 1$, si su pmf $p : \mathcal{C} \to [0,1]$ es

$$p(y \mid \theta) = \prod_{c=1}^{C} \theta_c^{\mathbb{I}(y=c)} \qquad \text{o, en notación one-hot,} \qquad p(\boldsymbol{y} \mid \theta) = \prod_{c=1}^{C} \theta_c^{y_c}$$

Interpretación: θ_c es la probabilidad de que y valga c, $p(y = c \mid \boldsymbol{\theta}) = \theta_c$ (convenimos $0^0 = 1$ y $0 \log 0 = 0$)

Sobre-parametrización: solo tenemos $C - 1$ parámetros libres por las restricciones sobre $\boldsymbol{\theta}$

Ejemplo: $C = 3, \ \boldsymbol{\theta}^t = (0.3, 0.2, 0.5)$

In [ ]:
```
import matplotlib.pyplot as plt; from scipy.stats import multinomial
t = [0.3, 0.2, 0.5]; Y = multinomial(1, t); print(Y.p, Y.rvs(3)[1, :])
fig = plt.subplots(figsize=(5, 1.25)); y = range(1, 4); plt.xticks(y); plt.bar(y, Y.p);
```

```
[0.3 0.2 0.5] [0 0 1]
```

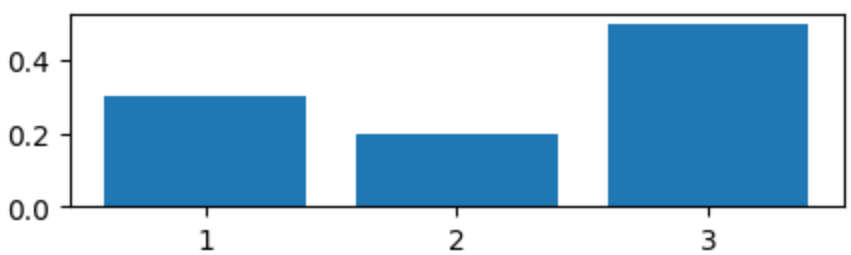

Función softmax: transforma logits $\boldsymbol{a} \in \mathbb{R}^C$ en un vector de probabilidades $[0,1]^C$

$$\mathcal{S}(\boldsymbol{a}) = \left(\frac{e^{a_1}}{\sum_{\tilde{c}} e^{a_{\tilde{c}}}}, \ldots, \frac{e^{a_C}}{\sum_{\tilde{c}} e^{a_{\tilde{c}}}} \right)^t \qquad \text{cumpliéndose} \qquad 0 \leq \mathcal{S}(\boldsymbol{a})_c \leq 1 \quad \text{y} \quad \sum_{c=1}^{C} \mathcal{S}(\boldsymbol{a})_c = 1$$

Ejemplo: $\boldsymbol{a} = (3,0,1)^t$, $\mathcal{S}(\boldsymbol{a}) = \left(\frac{e^3}{e^3+1+e}, \frac{1}{e^3+1+e}, \frac{e}{e^3+1+e} \right)^t = (0.8438, 0.0420, 0.1142)^t$

In [ ]:
```
import numpy as np; import matplotlib.pyplot as plt
def softmax(a):
        e = np.exp((1.0 * np.array(a))); return e / np.sum(e)
a = np.array([3, 0, 1]); fig = plt.subplots(figsize=(5, 3));
y = range(1, 4); plt.xticks(y); plt.bar(y, softmax(a));
```

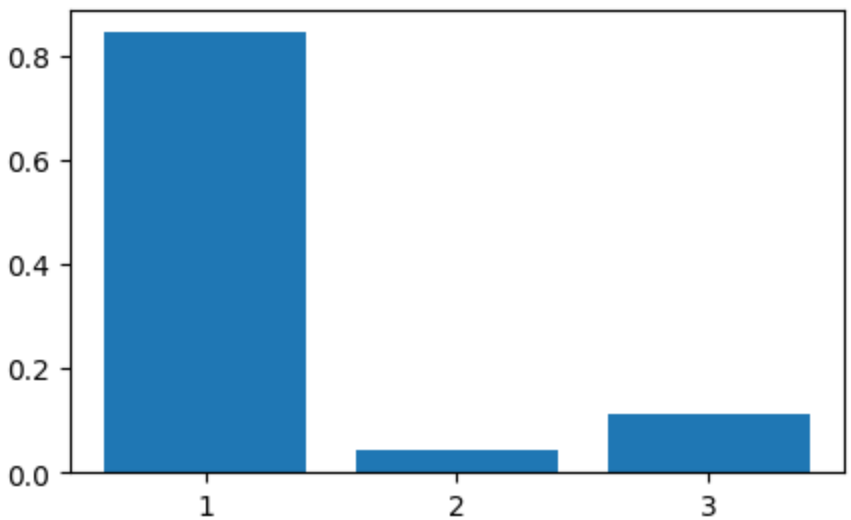

4 Distribución Gaussiana

Función de densidad de probabilidad (pdf) Gaussiana: $Y \sim \mathcal{N}(y \mid \mu, \sigma^2) = \dfrac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\dfrac{1}{2\sigma^2}(y-\mu)^2\right)$

In [ ]:
```
import numpy as np; import matplotlib.pyplot as plt; from scipy.stats import norm
Y = norm(0, 1); y = np.linspace(-3, 3, 200); fig = plt.subplots(figsize=(5, 2))
plt.grid(); plt.xlim(-3, 3); plt.ylim(0, .4); plt.plot(y, Y.pdf(y));
```

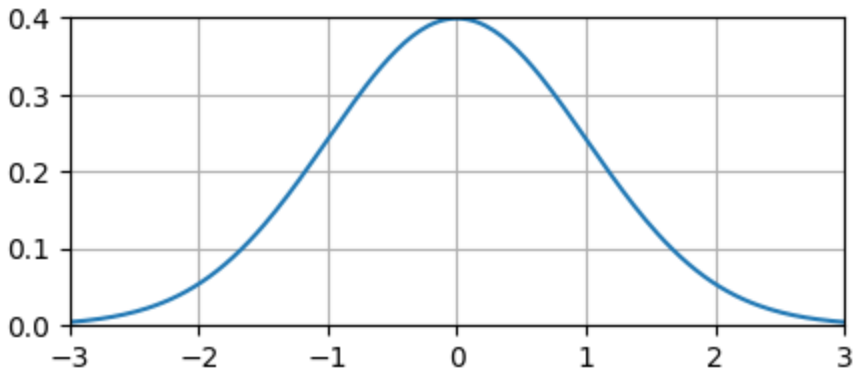

Covarianza entre dos variables aleatorias X e Y: mide hasta qué grado X e Y están (linealmente) relacionadas

$$\mathrm{Cov}[X, Y] = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

Gaussiana multivariada: $\boldsymbol{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, $\boldsymbol{x} \in \mathbb{R}^D$, **media** $\boldsymbol{\mu} = \mathbb{E}[\boldsymbol{x}] \in \mathbb{R}^D$, **covarianzas** $\boldsymbol{\Sigma} = \mathrm{Cov}[\boldsymbol{x}] \in \mathbb{R}^{D \times D}$

$$p(\boldsymbol{x} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\left[-\frac{1}{2}(\boldsymbol{x} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1}(\boldsymbol{x} - \boldsymbol{\mu})\right]$$

Tipos de Gaussianas según estructura de $\boldsymbol{\Sigma}$:

- **Esférica:** $\boldsymbol{\Sigma} = \sigma^2 \mathbf{I}$, con un único parámetro e isodensidades hiperesféricas
- **Diagonal:** $\boldsymbol{\Sigma} = \mathrm{diag}(\sigma_1^2, \ldots, \sigma_D^2)$, D parámetros, isodensidades hiperelipsoidales de semiejes paralelos a la base
- **General:** $\boldsymbol{\Sigma}$ no diagonal: $D(D+1)/2$ parámetros, isodensidades hiperelipsoidales de semiejes oblicuos a la base

In [ ]:
```
import numpy as np; import matplotlib.pyplot as plt; from scipy.stats import multivariate_normal
R = np.linspace(-3.5, 3.5, 30); x, y = np.meshgrid(R, R); me, Se = [0, 0], [[1, 0], [0, 1]]
md, Sd = [0, 0], [[1, 0], [0, 3]]; mg, Sg = [0, 0], [[2., 1.3], [1.3, 2.]]
fig = plt.figure(figsize=(15, 5.25)); fig.tight_layout()
for i, (m, S) in enumerate(zip((me, md, mg), (Se, Sd, Sg)), start=1):
    z = multivariate_normal(m, S).pdf(np.dstack((x, y)))
    ax = fig.add_subplot(2, 3, i, projection='3d'); ax.set_title(f'$S={S}$'.format(S))
    ax.plot_surface(x, y, z, color='white', edgecolor="black", lw=.5)
    ax = fig.add_subplot(2, 3, i+3, aspect='equal')
    cp = ax.contourf(x, y, z, 10, cmap='RdBu_r'); plt.colorbar(cp, ax=ax);
```

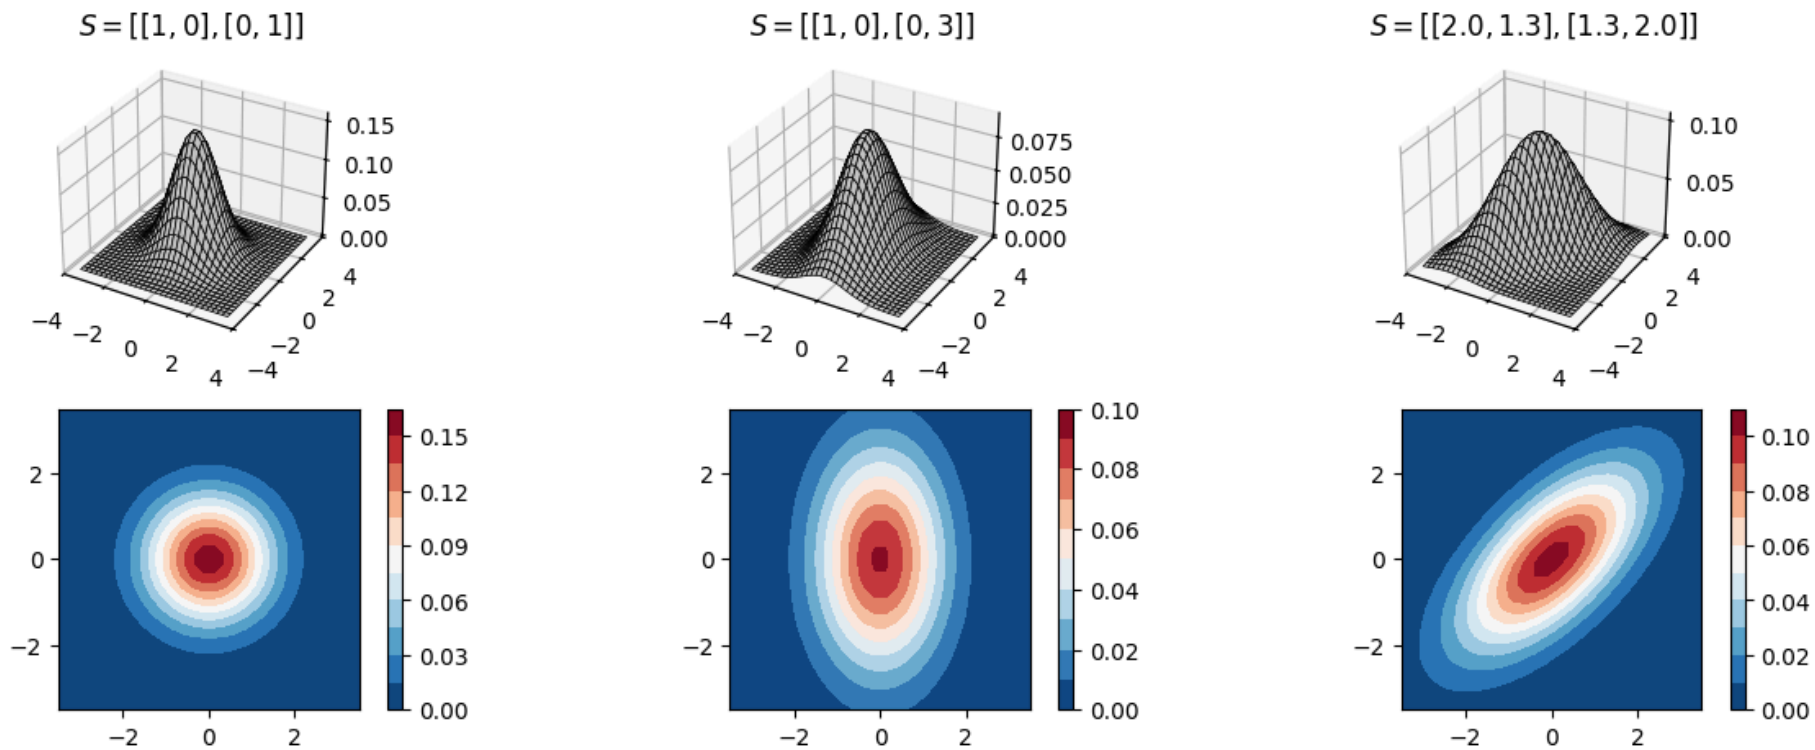

5 Entropía

Entropía de una distribución discreta: $\boldsymbol{y} \in [0,1]^C, \quad \sum_c y_c = 1$

$$\mathbb{H}(\boldsymbol{y}) = -\sum_c y_c \log_2 y_c$$

Distribución de máxima entropía: $\boldsymbol{y} = \frac{1}{C}\mathbf{1}_C$

$$\mathbb{H}(\boldsymbol{y}) = -\sum_c \frac{1}{C}\log_2 \frac{1}{C} = -\log_2 \frac{1}{C} = \log_2 C$$

Distribución de mínima entropía: $\boldsymbol{y} = \text{one-hot}(c^*)$ para algún $c^* \in \{1,\dots,C\}$

$$\mathbb{H}(\boldsymbol{y}) = -1\log_2 1 - \sum_{c\neq c^*} 0\ \log_2 0 = 0$$

Entropía cruzada:

$$\mathbb{H}(\boldsymbol{y},\hat{\boldsymbol{y}}) = -\sum_c\ y_c \log_2 \hat{y}_c \quad \text{cumple} \quad \mathbb{H}(\boldsymbol{y},\hat{\boldsymbol{y}}) \geq \mathbb{H}(\boldsymbol{y},\boldsymbol{y}) = \mathbb{H}(\boldsymbol{y})$$

Entropía cruzada binaria: entropía cruzada para $C = 2$ clases

$$\mathbb{H}(y,\hat{y}) = -y\log_2 \hat{y} - (1-y)\log_2(1-\hat{y})$$

6 Estimación máximo-verosímil (MLE)

Modelo incondicional: MLE de $\boldsymbol{\theta}$ con respecto a $\mathcal{D} = \{\boldsymbol{y}_1, \ldots, \boldsymbol{y}_N\}$ iid según $p(\boldsymbol{y} \mid \boldsymbol{\theta})$

$$\begin{aligned}
\hat{\boldsymbol{\theta}}_{\text{mle}} &= \operatorname{argmax}_{\boldsymbol{\theta}} \ \mathrm{L}(\boldsymbol{\theta}) \quad \text{con} \quad \mathrm{L}(\boldsymbol{\theta}) = p(\mathcal{D} \mid \boldsymbol{\theta}) = \prod\nolimits_n p(\boldsymbol{y}_n \mid \boldsymbol{\theta}) \\
&= \operatorname{argmax}_{\boldsymbol{\theta}} \ \mathrm{LL}(\boldsymbol{\theta}) \quad \text{con} \quad \mathrm{LL}(\boldsymbol{\theta}) = \log \mathrm{L}(\boldsymbol{\theta}) = \sum\nolimits_n \log p(\boldsymbol{y}_n \mid \boldsymbol{\theta}) \\
&= \operatorname{argmin}_{\boldsymbol{\theta}} \ \mathrm{NLL}(\boldsymbol{\theta}) \quad \text{con} \quad \mathrm{NLL}(\boldsymbol{\theta}) = -\mathrm{LL}(\boldsymbol{\theta}) = -\sum\nolimits_n \log p(\boldsymbol{y}_n \mid \boldsymbol{\theta})
\end{aligned}$$

- **Bernoulli:** $\mathcal{D} = \{y_1, \ldots, y_N\}, \quad p(y_n \mid \theta) = \mathrm{Ber}(y \mid \theta)$

$$\hat{\theta} = \frac{N_1}{N} \quad \text{con} \quad N_1 = \sum\nolimits_n \mathbb{I}(y_n = 1)$$

- **Categórica:** $\mathcal{D} = \{y_1, \ldots, y_N\}, \quad p(y_n \mid \boldsymbol{\theta}) = \mathrm{Cat}(y \mid \boldsymbol{\theta})$

$$\hat{\theta}_c = \frac{N_c}{N} \quad \text{con} \quad N_c = \sum\nolimits_n \mathbb{I}(y_n = c)$$

- **Gaussiana 1d:** $\mathcal{D} = \{y_1, \ldots, y_N\}, \quad p(y_n \mid \boldsymbol{\theta}) = \mathcal{N}(y \mid \mu, \sigma^2)$

$$\hat{\mu} = \bar{y} \quad \text{y} \quad \hat{\sigma}^2 = \frac{1}{N} \sum\nolimits_n (y_n - \hat{\mu})^2$$

- **Gaussiana:** $\mathcal{D} = \{\boldsymbol{y}_1, \ldots, \boldsymbol{y}_N\}, \ p(\boldsymbol{y}_n \mid \boldsymbol{\theta}) = \mathcal{N}(\boldsymbol{y} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma})$

$$\hat{\boldsymbol{\mu}} = \bar{\boldsymbol{y}} \quad \text{y} \quad \hat{\boldsymbol{\Sigma}} = \frac{1}{N} \sum\nolimits_n (\boldsymbol{y}_n - \hat{\boldsymbol{\mu}})(\boldsymbol{y}_n - \hat{\boldsymbol{\mu}})^t$$

Ejercicio: demuestra los casos Bernoulli, categórica y Gaussiana 1d

Bernoulli: $\mathcal{D} = \{y_1, \ldots, y_N\}, \quad p(y_n \mid \theta) = \mathrm{Ber}(y \mid \theta)$

$$
\begin{aligned}
\mathrm{NLL}(\theta) &= -\log \prod_{n=1}^{N} p(y_n \mid \theta) \\
&= -\log \prod_{n=1}^{N} \theta^{\mathbb{I}(y_n=1)} (1-\theta)^{\mathbb{I}(y_n=0)} \\
&= -\sum_{n=1}^{N} \mathbb{I}(y_n = 1) \log \theta + \mathbb{I}(y_n = 0) \log(1-\theta) \\
&= -[N_1 \log \theta + N_0 \log(1-\theta)] \quad \text{con} \quad N_1 = \sum_n \mathbb{I}(y_n = 1) \quad \text{y} \quad N_0 = \sum_n \mathbb{I}(y_n = 0)
\end{aligned}
$$

$$
\frac{d}{d\theta} \mathrm{NLL}(\theta) = \frac{-N_1}{\theta} + \frac{N_0}{1-\theta}\Big|_{\hat{\theta}} = 0 \;\rightarrow\; \hat{\theta} = \frac{N_1}{N}
$$

Categórica: $\mathcal{D} = \{y_1, \ldots, y_N\}, \quad p(y_n \mid \boldsymbol{\theta}) = \mathrm{Cat}(y \mid \boldsymbol{\theta})$

$$
\begin{aligned}
\mathrm{NLL}(\boldsymbol{\theta}) &= -\log \prod_{n=1}^{N} p(y_n \mid \boldsymbol{\theta}) \\
&= -\log \prod_{n=1}^{N} \prod_{c=1}^{C} \theta_c^{\mathbb{I}(y_n = c)} \\
&= -\sum_{n=1}^{N} \sum_{c=1}^{C} \mathbb{I}(y_n = c) \log \theta_c \\
&= -\sum_{c=1}^{C} N_c \log \theta_c \quad \text{con} \quad N_c = \sum_{n} \mathbb{I}(y_n = c)
\end{aligned}
$$

$$
\mathcal{L}(\boldsymbol{\theta}, \lambda) = -\sum_{c} N_c \log \theta_c - \lambda \left(1 - \sum_{c} \theta_c\right)
$$

$$
\begin{aligned}
\frac{\partial \mathcal{L}}{\partial \theta_c} &= -\frac{N_c}{\theta_c} + \lambda \\
\frac{\partial \mathcal{L}}{\lambda} &= -1 + \sum_{c} \theta_c \\
\hat{\theta}_c &= \frac{N_c}{N} \qquad \text{(igualando a cero las derivadas)}
\end{aligned}
$$

Gaussiana 1d: $\mathcal{D} = \{y_1, \ldots, y_N\}, \quad p(y_n \mid \boldsymbol{\theta}) = \mathcal{N}(y \mid \mu, \sigma^2)$

$$
\begin{aligned}
\mathrm{NLL}(\mu, \sigma^2) &= -\log \prod_{n=1}^{N} p(y_n \mid \theta) \\
&= -\sum_n \log \left[\left(\frac{1}{2\pi\sigma^2} \right)^{\frac{1}{2}} \exp\left(-\frac{1}{2\sigma^2} (y_n - \mu)^2 \right) \right] \\
&= \frac{N}{2} \log(2\pi\sigma^2) + \frac{1}{2\sigma^2} \sum_n (y_n - \mu)^2
\end{aligned}
$$

$$
\begin{aligned}
\frac{\partial \mathrm{NLL}}{\partial \mu} &= \frac{1}{\sigma^2} \sum_n (\mu - y_n) = \frac{N}{\sigma^2} (\mu - \bar{y}) \Big|_{\hat{\boldsymbol{\theta}}} = 0 \;\rightarrow\; \hat{\mu} = \bar{y} \\
\frac{\partial \mathrm{NLL}}{\partial \sigma} &= \frac{N}{\sigma} - \frac{1}{\sigma^3} \sum_n (y_n - \mu)^2 \Big|_{\hat{\boldsymbol{\theta}}} = 0 \;\rightarrow\; \hat{\sigma}^2 = \frac{1}{N} \sum_n (y_n - \hat{\mu})^2
\end{aligned}
$$

Modelo condicional: MLE de $\boldsymbol{\theta}$ con respecto a $\mathcal{D} = \{(\boldsymbol{x}_n, \boldsymbol{y}_n)\}$ iid según $p(\boldsymbol{x}, \boldsymbol{y} \mid \boldsymbol{\theta})$

$$\hat{\boldsymbol{\theta}}_{\text{mle}} = \operatorname{argmin}_{\boldsymbol{\theta}} \ \text{NLL}(\boldsymbol{\theta}) \quad \text{con} \quad \text{NLL}(\boldsymbol{\theta}) = -\sum\nolimits_n \ \log p(\boldsymbol{y}_n \mid \boldsymbol{x}_n, \boldsymbol{\theta})$$

- **Cálculo:** suele hacerse iterativamente, mediante descenso por gradiente (estocástico)

Modelo conjunto: MLE de $\boldsymbol{\theta}$ con respecto a $\mathcal{D} = \{(\boldsymbol{x}_n, \boldsymbol{y}_n)\}$ iid según $p(\boldsymbol{x}, \boldsymbol{y} \mid \boldsymbol{\theta})$

$$\hat{\boldsymbol{\theta}}_{\text{mle}} = \operatorname{argmin}_{\boldsymbol{\theta}} \ \text{NLL}(\boldsymbol{\theta}) \quad \text{con} \quad \text{NLL}(\boldsymbol{\theta}) = -\sum\nolimits_n \ \log p(\boldsymbol{x}_n, \boldsymbol{y}_n \mid \boldsymbol{\theta})$$

- **Distinto del MLE del modelo condicional:**

$$\begin{aligned}
\hat{\boldsymbol{\theta}}_{\text{mle}} &= \operatorname*{argmin}_{\boldsymbol{\theta}} -\sum_{n=1}^{N} \log p(\boldsymbol{y}_n \mid \boldsymbol{x}_n, \boldsymbol{\theta}) \\
&= \operatorname*{argmin}_{\boldsymbol{\theta}} -\sum_{n=1}^{N} \log \frac{p(\boldsymbol{x}_n, \boldsymbol{y}_n \mid \boldsymbol{\theta})}{p(\boldsymbol{x}_n \mid \boldsymbol{\theta})} \\
&= \operatorname*{argmin}_{\boldsymbol{\theta}} -\sum_{n=1}^{N} \log p(\boldsymbol{x}_n, \boldsymbol{y}_n \mid \boldsymbol{\theta}) \underbrace{- \log p(\boldsymbol{x}_n \mid \boldsymbol{\theta})}_{\text{depende de toda } \boldsymbol{y}}
\end{aligned}$$

- **Cálculo:** suele ser sencillo, clase a clase, mediante conteo y promediado con los datos de la clase

7 Minimización del riesgo empírico (ERM)

ERM: ERM de $\boldsymbol{\theta}$ con respecto a $\mathcal{D} = \{(\boldsymbol{x}_n, \boldsymbol{y}_n)\}$ iid según $p(\boldsymbol{x}, \boldsymbol{y} \mid \boldsymbol{\theta})$, para pérdida genérica $\ell(\boldsymbol{y}, \hat{\boldsymbol{y}})$

$$\hat{\boldsymbol{\theta}}_{\text{erm}} = \operatorname{argmin}_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta}) \quad \text{con} \quad \mathcal{L}(\boldsymbol{\theta}) = \frac{1}{N} \sum\nolimits_n \ell(\boldsymbol{y}_n, \hat{\boldsymbol{y}}_n)$$

Pérdida 01: $\ell_{01}(y, \hat{y}) = \mathbb{I}(y \neq \hat{y})$ para clasificadores probabilísticos o no, pero no es diferenciable

Log-pérdida: $\ell(\boldsymbol{y}, \hat{\boldsymbol{y}}) = -\log p(\boldsymbol{y} \mid \boldsymbol{x}, \boldsymbol{\theta})$ particulariza la ERM a la MLE (normalizada por N)

$$\mathcal{L}(\boldsymbol{\theta}) = \text{NLL}(\boldsymbol{\theta}) = -\frac{1}{N} \sum\nolimits_n \log p(\boldsymbol{y}_n \mid \boldsymbol{x}_n, \boldsymbol{\theta})$$

Bernoulli condicional: $y \in \{0, 1\}, \quad p(y \mid \boldsymbol{x}, \boldsymbol{\theta}) = \text{Ber}(y \mid \mu), \quad \hat{y} = \mu = f(\boldsymbol{x}, \boldsymbol{\theta})$

$$\ell(y, \hat{y}) = -\log\, p(y \mid \boldsymbol{x}, \boldsymbol{\theta}) = -y \log \hat{y} - (1 - y) \log(1 - \hat{y}) = \mathbb{H}(y, \hat{y})$$

Categórica condicional: $\boldsymbol{y} \in \{0, 1\}^C,\ \sum_c y_c = 1, \quad p(\boldsymbol{y} \mid \boldsymbol{x}, \boldsymbol{\theta}) = \text{Cat}(\boldsymbol{y} \mid \boldsymbol{\mu}), \quad \hat{\boldsymbol{y}} = \boldsymbol{\mu} = f(\boldsymbol{x}, \boldsymbol{\theta})$

$$\ell(\boldsymbol{y}, \hat{\boldsymbol{y}}) = -\log p(\boldsymbol{y} \mid \boldsymbol{x}, \boldsymbol{\theta}) = -\sum_c y_c \log \hat{y}_c = \mathbb{H}(\boldsymbol{y}, \hat{\boldsymbol{y}})$$

Gaussiana (1d) condicional: $y \in \mathbb{R}, \quad p(y \mid \boldsymbol{x}, \boldsymbol{\theta}) = \mathcal{N}(y \mid \mu, \sigma^2), \quad \hat{y} = \mu = f(\boldsymbol{x}, \boldsymbol{\theta}), \quad \sigma^2$ fija

$$\ell(y, \hat{y}) = -\log\, p(y \mid \boldsymbol{x}, \boldsymbol{\theta}) = -\frac{1}{2} \log(2\pi\sigma^2) + \frac{1}{2\sigma^2} (y - \hat{y})^2 \equiv (y - \hat{y})^2$$

Ejercicio: halla la derivada (o gradiente) de la log-pérdida respecto de la predicción en los tres casos anteriores

Entropía cruzada binaria (Bernoulli condicional): $\ell(y, \hat{y}) = -y \log \hat{y} - (1-y) \log(1-\hat{y})$

$$\begin{aligned}\frac{\partial \ell(y, \hat{y})}{\partial \hat{y}} &= -\frac{y}{\hat{y}} + \frac{1-y}{1-\hat{y}} \\ &= \frac{\hat{y} - y}{\hat{y}(1-\hat{y})}\end{aligned}$$

Entropía cruzada (categórica condicional): $\ell(\boldsymbol{y}, \hat{\boldsymbol{y}}) = -\sum_c y_c \log \hat{y}_c = -\boldsymbol{y}^t \log(\hat{\boldsymbol{y}})$

$$\begin{aligned}\frac{\partial \ell(\boldsymbol{y}, \hat{\boldsymbol{y}})}{\partial \hat{\boldsymbol{y}}} &= \left(\frac{\partial \ell(\boldsymbol{y}, \hat{\boldsymbol{y}})}{\partial \hat{y}_1}, \cdots, \frac{\partial \ell(\boldsymbol{y}, \hat{\boldsymbol{y}})}{\partial \hat{y}_C} \right) \\ &= \left(-\frac{y_1}{\hat{y}_1}, \ldots, -\frac{y_C}{\hat{y}_C} \right) \\ &= -\boldsymbol{y}^t \oslash \hat{\boldsymbol{y}}^t \quad \text{(división Hadamard)}\end{aligned}$$

Pérdida cuadrática (Gaussiana (1d) condicional): $\ell_2(y, \hat{y}) = (y - \hat{y})^2$

$$\frac{\partial \ell_2(y, \hat{y})}{\partial \hat{y}} = 2(\hat{y} - y)$$

8 Regularización

Sobre-entrenamiento (overfitting): problema fundamental de MLE y, en general, ERM, asociado a la minimización de la pérdida sobre los datos de entrenamiento, ya que conduce a modelos **sobre-entrenados** que **no generalizan** (bien)

Regularización: añade una **penalización (penalty)** a la pérdida mediante alguna forma de **penalización de complejidad** $C(\boldsymbol{\theta})$ cuyo peso depende de un **parámetro de regularización** $\lambda \geq 0$

$$\mathcal{L}(\boldsymbol{\theta}, \lambda) = \frac{1}{N} \sum_n \ell(\boldsymbol{y}_n, \hat{\boldsymbol{y}}_n) + \lambda\, C(\boldsymbol{\theta})$$

Penalización de complejidad usual: asume dado un **prior** más o menos plano, $p(\boldsymbol{\theta})$

$$C(\boldsymbol{\theta}) = -\log p(\boldsymbol{\theta})$$

Estimación maximum a posteriori (MAP): asumiendo $p(\boldsymbol{\theta} \mid \mathcal{D}) = \delta(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_{\text{map}})$ y log-pérdida

$$\hat{\boldsymbol{\theta}}_{\text{map}} = \operatorname*{argmax}_{\boldsymbol{\theta}} \ \log p(\boldsymbol{\theta} \mid \mathcal{D}) = \operatorname*{argmin}_{\boldsymbol{\theta}} \ \text{NLL}(\boldsymbol{\theta}) - \lambda \log p(\boldsymbol{\theta})$$

- λ **demasiado pequeño:** equivale a minimizar el riesgo empírico y acabar con un modelo **sobre-ajustado**
- λ **demasiado grande:** equivale a no desviarse mucho del prior y acabar con un modelo **sub-ajustado**

Dificultad para estimar λ: con los datos de entrenamiento obtenemos $\hat{\lambda} = 0$

Validación: método más popular y sencillo para escoger λ

- Dividimos los datos en un conjunto de **entrenamiento** $\mathcal{D}_{\text{train}}$ y otro de **validación o desarrollo** $\mathcal{D}_{\text{valid}}$
- Cada valor de λ se evalúa con $\mathcal{D}_{\text{valid}}$ tras ajustar el modelo con $\mathcal{D}_{\text{train}}$
- Elegimos el λ que proporciona mejor rendimiento en $\mathcal{D}_{\text{valid}}$

K-fold cross validation (K-CV): versión refinada de validación que aprovecha todos los datos para validar

- Dividimos los datos en K bloques, $\mathcal{D}_1, \ldots, \mathcal{D}_K$
- Cada valor de λ se evalúa con cada bloque $\mathcal{D}_k$ tras ajustar el modelo con el resto de bloques, $\mathcal{D}_{-k}$
- Elegimos el λ que proporciona mejor rendimiento promedio

Leave-one-out (LOO): K-CV con tantos bloques como datos

Estimación de hiperparámetros en general: también puede usarse validación, K-CV y LOO

Otras técnicas usuales de regularización:

- **Terminación temprana (early stopping):** si se usa un algoritmo iterativo de entrenamiento, podemos validar el rendimiento del modelo tras cada iteración y terminar antes de convergencia si se observa sobre-entrenamiento

- **Uso de más datos:** dado un modelo de complejidad fija, la posibilidad de sobre-ajuste decrece al aumentar los datos

Estimación del riesgo teórico: mediante un conjunto de **test** $\mathcal{D}_{\text{test}}$ separado de los datos

9 Decisión

Inferencia Bayesiana: cálculo de la **posterior** $p(H \mid \boldsymbol{x})$ mediante la regla de Bayes actualizar nuestras creencias sobre cantidades ocultas H a partir de datos $\boldsymbol{x}$

Teoría de la decisión Bayesiana: usa la inferencia para decidir cuál es la mejor de las posibles **acciones** a realizar

Agente: debe escoger una acción de un conjunto de acciones posibles, $\mathcal{A}$

Estado de la naturaleza: $h \in \mathcal{H}$, condiciona los costes y beneficios que se derivan de tomar cada acción posible

Función de pérdida: indica el coste incurrido al tomar la acción $a \in \mathcal{A}$ cuando el estado de la naturaleza es $h \in \mathcal{H}$

$$\ell(h, a)$$

Riesgo (pérdida) esperado a posteriori: de a tras observar $\boldsymbol{x}$

$$R(a \mid \boldsymbol{x}) = \mathbb{E}_{p(h|\boldsymbol{x})}[\ell(h, a)] = \sum_{h \in \mathcal{H}} \ell(h, a)\, p(h \mid \boldsymbol{x})$$

Política óptima o estimador de Bayes: obtiene una acción de mínimo riesgo por cada observación posible

$$\pi^*(\boldsymbol{x}) = \operatorname*{argmin}_{a \in \mathcal{A}} \; R(a \mid \boldsymbol{x})$$

Problemas de clasificación

Estados de la naturaleza y acciones: etiquetas de clase, $\mathcal{H} = \mathcal{Y} = \{1, \ldots, C\}$ y $\mathcal{A} = \mathcal{Y}$

Pérdida 01 esperada a posteriori: la probabilidad de error a posteriori es uno menos la de acertar a posteriori

$$R(\hat{y} \mid \boldsymbol{x}) = \sum_{y} \ell_{01}(y, \hat{y})\, p(y \mid \boldsymbol{x}) = \sum_{y \neq \hat{y}} p(y \mid \boldsymbol{x}) = 1 - p(\hat{y} \mid \boldsymbol{x})$$

Esstimador de Bayes: $\pi(\boldsymbol{x}) = \operatorname{argmax}_{y \in \mathcal{Y}}\ p(y \mid \boldsymbol{x})$ **estimador MAP** o **moda** de la posterior

Matriz de confusión: $\mathcal{D} = \{(y_m, \hat{y}_m)\}$, $\mathbf{M} = [M_{y,\hat{y}}]$ con $M_{y,\hat{y}} = \sum_m \mathbb{I}(y_m = y)\mathbb{I}(\hat{y}_m = \hat{y})$

y	$\hat{1}$	$\hat{2}$	$\cdots$	$\hat{C}$	Suma fila
1	$M_{1,\hat{1}}$	$M_{1,\hat{2}}$	$\cdots$	$M_{1,\hat{C}}$	$M_{1,:}$
2	$M_{2,\hat{1}}$	$M_{2,\hat{2}}$	$\cdots$	$M_{2,\hat{C}}$	$M_{2,:}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
C	$M_{C,\hat{1}}$	$M_{C,\hat{2}}$	$\cdots$	$M_{C,\hat{C}}$	$M_{C,:}$
Suma:	$M_{:,\hat{1}}$	$M_{:,\hat{2}}$	$\cdots$	$M_{:,\hat{C}}$	M

Normalización por filas: estimación empírica de $p(\hat{y} \mid y)$

Normalización por columnas: estimación empírica de $p(y \mid \hat{y})$

Normalización por filas y columnas: estimación empírica de $p(y, \hat{y})$

Análisis de una clase específica: se reduce a matriz binaria tomando el resto de clases como clase negativa

Problemas de regresión

Estados de la naturaleza y acciones: reales, $\mathcal{H} = \mathcal{A} = \mathcal{Y} = \mathbb{R}$

Pérdida L2 (ℓ_2, cuadrática o error cuadrático): $\ell_2(h, a) = (h - a)^2$

Pérdida L2 esperada a posteriori:

$$R(a \mid \boldsymbol{x}) = \mathbb{E}[(h - a)^2 \mid \boldsymbol{x}] = \mathbb{E}[h^2 \mid \boldsymbol{x}] - 2a\mathbb{E}[h \mid \boldsymbol{x}] + a^2$$

Regresor de Bayes L2 o minimum mean squared error (MMSE): media a posteriori

$$\frac{\partial}{\partial a} R(a \mid \boldsymbol{x}) = -2\mathbb{E}[h \mid \boldsymbol{x}] + 2a = 0 \quad \rightarrow \quad \pi(\boldsymbol{x}) = \mathbb{E}[h \mid \boldsymbol{x}] = \int h\, p(h \mid \boldsymbol{x})\, dh$$