TRABAJOS ASIGNATURA **SAR**

Curso 2025-26

OBJETIVO: preparar y realizar una presentación pública sobre un tema relacionado con la asignatura.

PROCEDIMIENTO:

1. Los alumnos formarán grupos de 4 componentes.
2. Cada grupo nos comunicará a través del **correo interno de la asignatura** dirigido a **Rol Profesor**, con fecha tope el **1 de marzo**:
    a. Los componentes del grupo (nombre completo de todos los componentes)
    b. El nombre del representante del grupo y su correo electrónico
    c. La lista ordenada por orden de preferencia de las propuestas de trabajos publicadas en este documento (por ejemplo: T5, T6, T1, …)
3. El **10 de marzo** publicaremos la asignación definitiva de trabajos a grupos.
4. El representante de cada grupo deberá subir hasta el día **4 de mayo** al PoliformaT en una tarea que se habilitará para ello la presentación .ppt o/y .pdf del trabajo elegido. A continuación, se muestra un esquema de una presentación genérica. La presentación deberá contener los nombres de los componentes del grupo.
5. Los días **11 y 18 de mayo** para el grupo de la tarde y los días **13 y 20 de mayo** para el grupo de la mañana se llevarán a cabo las presentaciones de los trabajos. Cada grupo dispondrá de **15 minutos** para la presentación, todos los miembros del grupo deben participar en dicha presentación.
6. Los profesores de la asignatura pueden realizar preguntas durante la presentación a cualquiera de los componentes del grupo.
7. En la lista de propuestas de trabajos que se relacionan a continuación, se indica el título de los capítulos de libro o artículos que deben servir de referencia principal para la preparación del trabajo. Se puede ampliar con otros documentos. En función del interés del grupo o de la extensión del capítulo de referencia, se puede trabajar sobre una parte de los contenidos del capítulo dejando otros aspectos sin tratar.
8. Si algún grupo tiene una propuesta alternativa no recogida en la lista de trabajos, debe ponerse en contacto con sus profesores para acordar el tema.

ESQUEMA GENERAL DE LA PRESENTACIÓN

- Título y autores
- Índice
- Introducción (se introduce el problema que se va a abordar)
- Desarrollo (se organiza en puntos y se desarrollan)
- Resumen de puntos más interesantes
- Bibliografía

CRITERIOS DE EVALUACIÓN DE LA PRESENTACIÓN

ORGANIZACIÓN DEL DISCURSO: Introducción

Se ha realizado una buena introducción del tema

Se ha presentado un índice de los contenidos a desarrollar

La introducción ha servido para ganar la atención de la audiencia y despertar el interés por el tema

ORGANIZACIÓN DEL DISCURSO: Desarrollo

La secuencia de contenidos ha sido lógica y coherente

Se han subrayado los conceptos a destacar

Se ha mostrado una buena capacidad de síntesis

ORGANIZACIÓN DEL DISCURSO: Conclusiones

Al final de la exposición, se ha incluido un resumen de la misma (conclusiones)

Se ha presentado una bibliografía adecuada al tema

VALORACIÓN DE LA EXPOSICIÓN

Se ha ajustado al tiempo establecido

Se ha transmitido firmeza y seguridad en el discurso

La exposición ha resultado clara e inteligible (usa un vocabulario adecuado y variado, se expresa con corrección, etc.)

La entonación y el volumen han facilitado el seguimiento del discurso

Los recursos utilizados se han empleado de manera adecuada (diseño, fuentes, colores de la presentación, etc)

PROPUESTAS DE TRABAJOS: En algunos casos se indica entre paréntesis un libro que contiene un capítulo específico para el tema del trabajo.

T1: Language Models for Information Retrieval ("An Introduction to Information Retrieval", C. Manning).

Se trata de desarrollar una labor de síntesis más alguna aportación nueva complementando alguno de los aspectos del uso de técnicas de modelado del lenguaje para la recuperación de información.

T2: Clustering de documentos de texto. En este trabajo hay que explicar algunos de los métodos existentes para el clustering de documentos. En el artículo que se menciona a continuación se puede ver el uso de las técnicas más actuales, basadas en redes neuronales, para abordar esta tarea.

"The performance of BERT as data representation of text clustering" Alvin Subakti, Hendri Murfi and Nora Hariadi. Journal of Big Data (2022)

https://journalofbigdata.springeropen.com/articles/10.1186/s40537-022-00564-9

T3: Recuperación de Imagen ("Recuperación de Información: un enfoque práctico y multidisciplinar", F. Cacheda, J.M. Fernández y J.F. Huete).

Se trata de desarrollar una labor de síntesis del capítulo centrando el trabajo en algunos de los tipos de representación del contenido.

T4: Relevance feedback and query expansion ("An Introduction to Information Retrieval", C. Manning).

Se trata de desarrollar una labor de síntesis más alguna aportación nueva, complementando por ejemplo alguna de las estrategias de retroalimentación de la relevancia o bien sobre algún método de reformulación de las consultas que se exponen en este capítulo.

T5: Análisis de la librería Haystack (https://haystack.deepset.ai/).

Se trata de explicar algunas de las utilidades de la librería. Haystack. Es una librería basada en Transformers de código abierto para crear sistemas de búsqueda que funcionan de manera inteligente en grandes colecciones de documentos.

T6: Detección de Plagio en texto ("Plagiarism Detection Using Stopword n-grams". Stamatatos E. Journal of the American Society for Information Science and Technology, December, 2011, http://onlinelibrary.wiley.com/doi/10.1002/asi.21630/pdf "Detección automática de plagio: de la copia exacta a la paráfrasis". Barrón A., Vila M., Rosso P. Panorama actual de la lingüística forense en el ámbito legal y policial: Teoría y práctica. 2010, http://users.dsic.upv.es/~prosso/resources/BarronEtAl_JLF10.pdf

Se trata de desarrollar una labor de comprensión y síntesis de los trabajos referenciados sin entrar en los detalles de la paráfrasis.

T7: Recommendation Systems ("Recuperación de Información: un enfoque práctico y multidisciplinar", F. Cacheda, J.M. Fernández y J.F. Huete) y ("Mining of Massive Datasets", A. Rajaraman).

Se trata de desarrollar una labor de síntesis más una aportación nueva, complementando por ejemplo algunos aspectos sobre la obtención de datos para la matriz de utilidad.

T8: Question Answering ("Speech and Language Processing", Jurafsky and Martin (http://web.stanford.edu/~jurafsky/slp3/).

Se trata de hacer un trabajo del tema donde se valorará la capacidad de síntesis y comprensión del mismo. No se deben contemplar los apartados de recuperación de información estudiados en clase.

T9: Summarization.

Se trata de desarrollar una labor de síntesis sobre los métodos de resumen automático de documentos. Para ello se usará el artículo "Text summarisation in_progress. A literatura review" Elena Lloret, Manuel Palomar (Artificial Intelligence Review V.37, pp-1-41, 2012), que proporciona una visión general de los métodos existentes, junto con el artículo "Abstractive summarization: An overview of the state of the art" Som Gupta, S.K Gupta. (Expert Systems with Applications, 2019 vol. 121, pp. 49-65)

T10: Twitter Sentiment Analysis. The State-of-the-Art in Twitter Sentiment Analysis: A Review and Benchmark Evaluation

Se trata de desarrollar una labor de síntesis sobre el artículo propuesto. Se valorará la capacidad de síntesis y comprensión del texto.

T11: Recuperación de Información entre lenguas distintas (Exploiting Wikipedia for cross-lingual and multilingual information retrieval, Philipp Sorg, Philipp Cimiano, Data & Knowledge Engineering, Volume 74, April 2012 // "Cross-lingual Information Retrieval with Explicit Semantic Analysis" Philipp Sorg, Philipp Cimiano, Working Notes for the CLEF 2008)

http://www.sciencedirect.com/science/article/pii/S0169023X12000213

Se trata de hacer un trabajo del tema donde se valorará la capacidad de síntesis y comprensión del mismo.

T12: Similitud de textos

"Una aproximación al uso de Word embeddings en una tarea de similitud de textos en español". T López-Solaz, JA Troyano, FJ Ortega y F Enríquez, Procesamiento del Lenguaje Natural, Revista nº 57, 2016, págs. 67-74.

http://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/5338).

"Similitud español-inglés a través de word embeddings". Fernando Enríquez, Fermín Cruz, F. Javier Ortega, José A. Troyano, Procesamiento del Lenguaje Natural, Revista nº 59, septiembre de 2017, pp. 31-38.

http://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/5490

Se trata de hacer un trabajo del tema donde se valorará la capacidad de síntesis y comprensión del mismo.

T13: Dbpedia ("DBpedia – A Large-scale, Multilingual Knowledge Base Extracted from Wikipedia". Lehmann et al., Semantic Web 1 (2012) 1–5).

http://svn.aksw.org/papers/2013/SWJ_DBpedia/public.pdf

Se trata de hacer un trabajo del tema donde se valorará la capacidad de síntesis y comprensión del mismo.

T14: ConceptNet (ConceptNet 5.5: An Open Multilingual Graph of General Knowledge. Robyn Speer, Joshua Chin, and Catherine Havasi. 2017, In proceedings of *AAAI*)

https://arxiv.org/abs/1612.03975

Se trata de hacer un trabajo del tema donde se valorará la capacidad de síntesis y comprensión del mismo.

T15: Representaciones densas de palabras y subpalabras: embeddings.

'Vector Semantics and Embeddings', sección 'Word2Vec' "Speech and Language Processing", Jurafsky and Martin (http://web.stanford.edu/~jurafsky/slp3/).

Modelos BERT: https://jalammar.github.io/illustrated-bert/

Se trata de hacer un trabajo del tema donde se valorará la capacidad de síntesis y comprensión del mismo.